



# Rede Adversária Generativa (Generative Adversarial Network - GAN)

Aluizio Fausto Ribeiro Araújo  
Universidade Federal de Pernambuco  
Centro de Informática


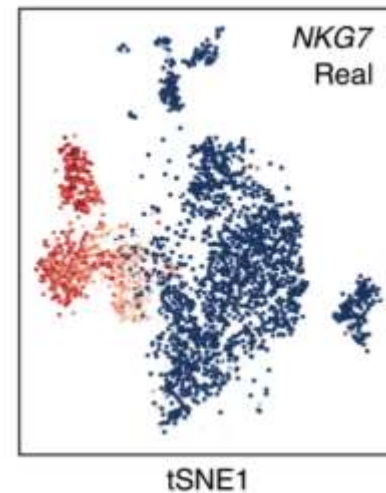



# Conteúdo

- Introdução
  - Motivação, apresentação, objetivos, aplicações
- Modelos Generativos
- Redes Adversárias Generativas
  - Arquitetura de GAN
  - Treinamento de GAN
- Extensões
- Aplicações
- Softwares e Referências

# Introdução

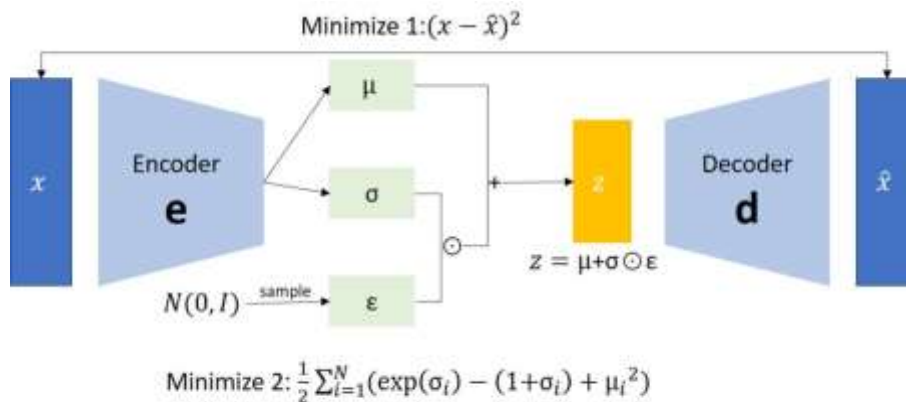
- Considere dois conjuntos de dados reais e aumentado:
  - Em uma dimensão
  - Em duas dimensões;



- Dados reais complementados por dados artificialmente gerados;

# Introdução

- A modelagem generativa visa construir um modelo, criando uma distribuição a partir de um conjunto de dados:
  - Os modelos generativos aprendem uma função de densidade de probabilidade a partir de um conjunto de treinamento e geram novas instâncias produzidas a partir da mesma distribuição;
- A qualidade do modelo pode ser avaliada por exemplos que ele produza e posterior comparação com dados reais;
- Visão esquemática geral de um modelo generativo:

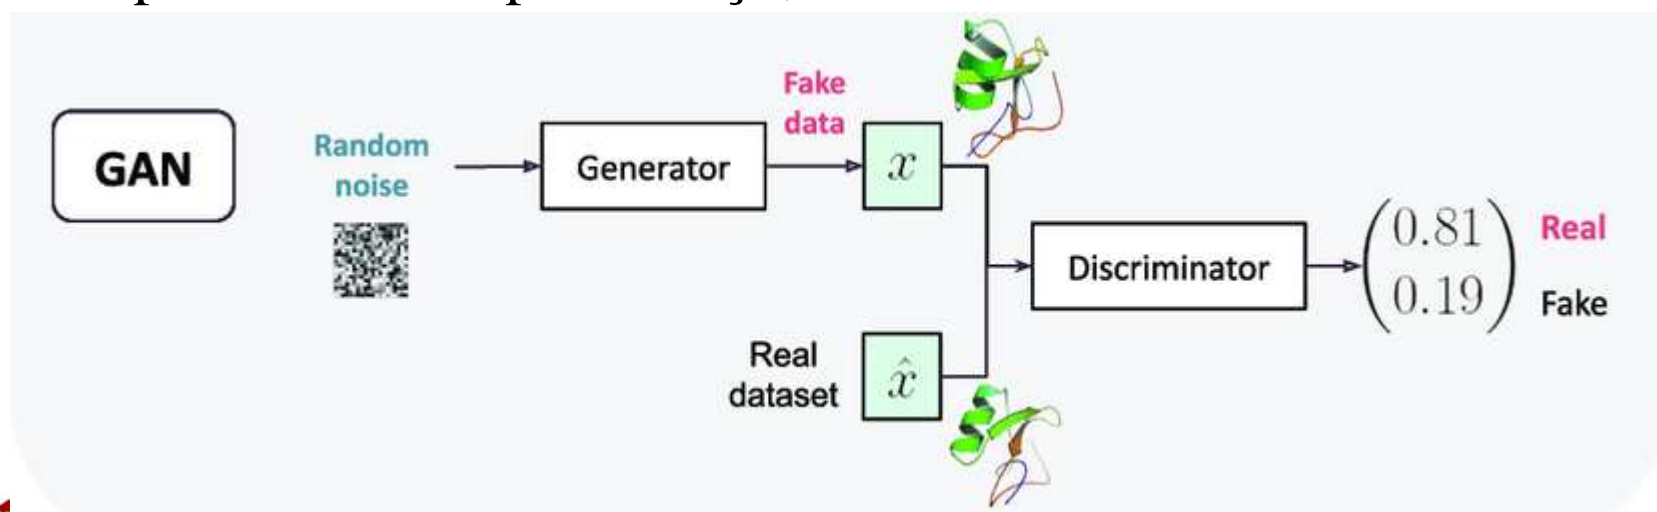


# Introdução

- Uma rede adversária generativa (GAN) é formada por duas redes neurais que interagem entre si na forma de um jogo de soma zero (vitória de um agente implica na derrota do outro);
- As GANs geram novos dados sintéticos semelhantes aos reais (mesmas estatísticas do conjunto de treinamento), colocando duas redes neurais (gerador e discriminador) uma contra a outra:
  - O Gerador tenta capturar a verdadeira distribuição de dados para gerar novas amostras (de qualquer origem como imagens ou textos),
    - Gerador produz padrões para tentar enganar o discriminador, i.e., ser considerado um exemplo verdadeiro;
  - O discriminador, geralmente um classificador binário visa classificar amostras geradas reais e falsas com precisão,
    - O discriminador usa treinamento indireto, ele avalia quão realista uma entrada parece;

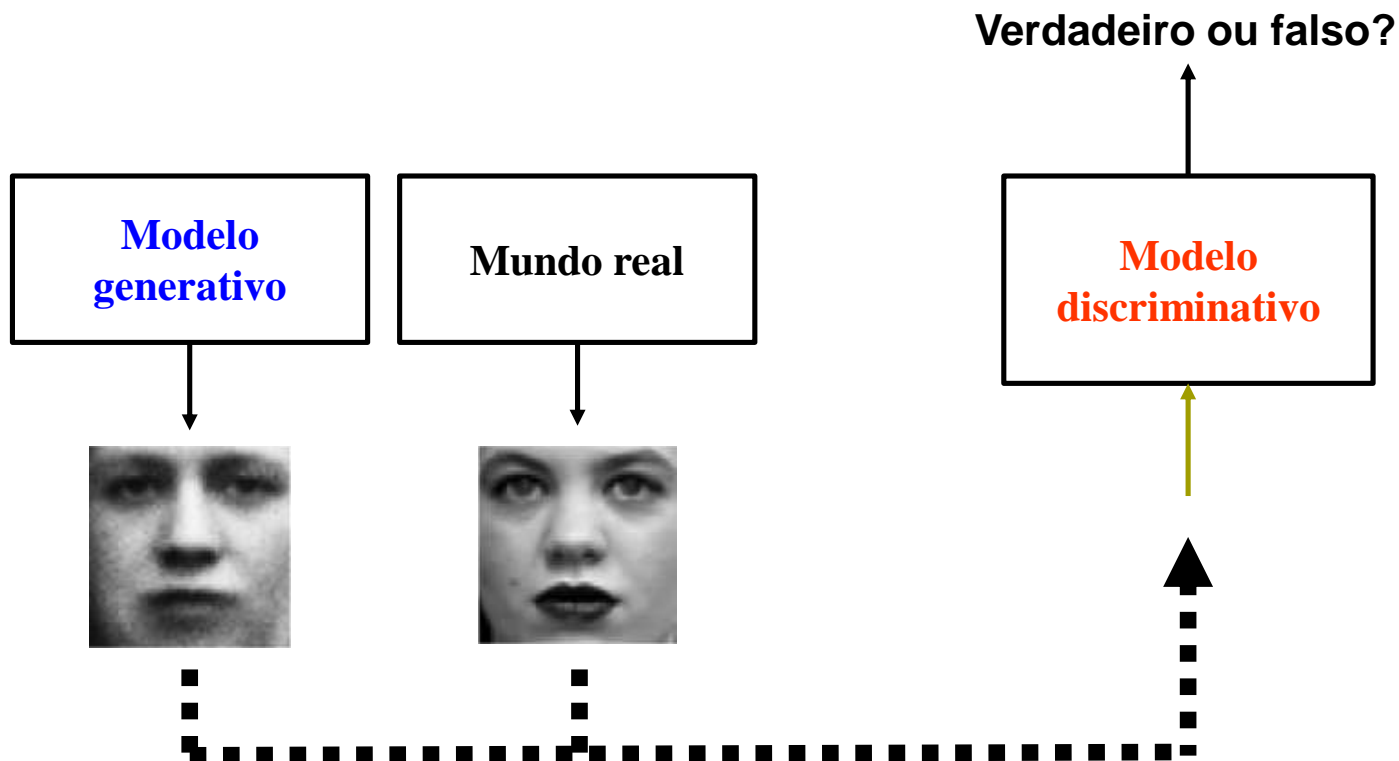
# Introdução

- Uma GAN aprende a gerar novos dados com as mesmas estatísticas de seu conjunto de treinamento,
  - E.g., GAN treinado em fotografias pode gerar novas fotografias que parecem autênticas para observadores humanos;
- Originalmente emprega aprendizagem não-supervisionada,
  - Também há modelos com aprendizagem semi-supervisionada, supervisionada e por reforço;



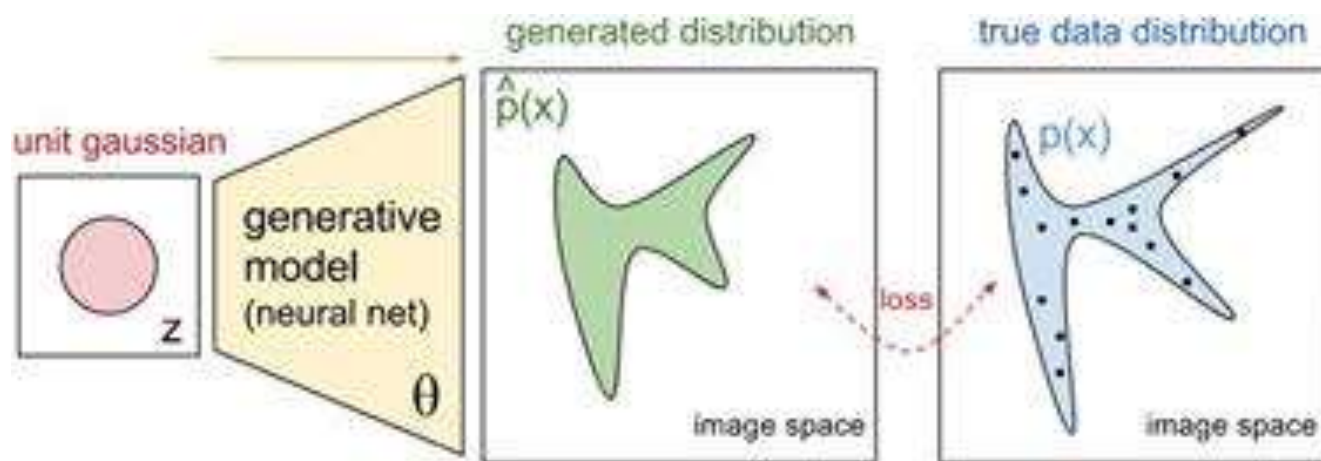
# Introdução

- Ilustração da atuação das GANs:
  - Geração de uma amostra e avaliação de seu realismo;



# Introdução


- Treinamento de GAN:
  - A rede geradora gera dados que parecem reais depois de aprender uma distribuição dos dados de treinamento;
  - A rede discriminadora, tipicamente uma CNN, aprende a rotular os exemplos como verdadeiros (reais) ou falsos (artificiais);
  - A categorização é usada para ajustar a rede geradora;





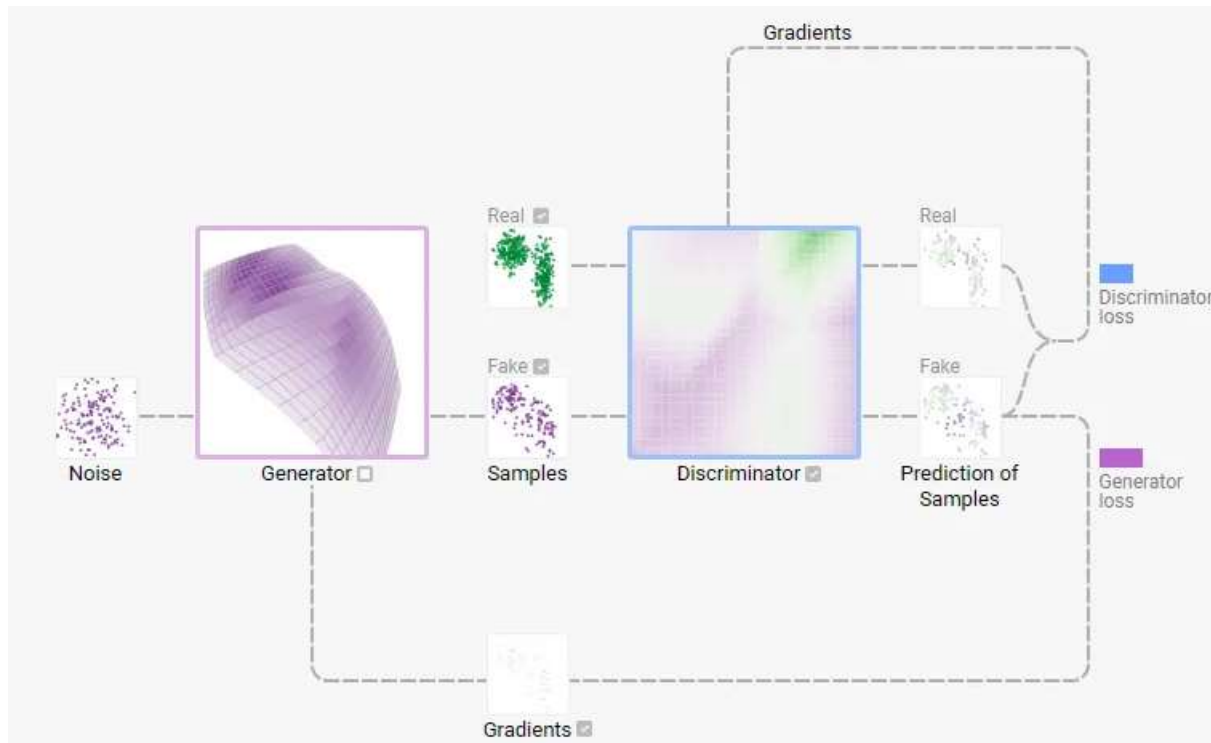
# Introdução

- GANs são treinadas até que iguale a distribuição generativa (verde) à distribuição geradora de dados (linha pontilhada) e o discriminador (linha azul pontilhada) seja incapaz de diferenciar entre as duas distribuições;



# Introdução

- GANs visam replicar distribuição de probabilidade,
- Para uma GAN, emprega-se funções de perda (f.p.):
  - Gerador: f.p. mede diferença entre dados gerados e de treinamento;
  - Discriminador : f.p. mede diferença entre dados gerados e reais;

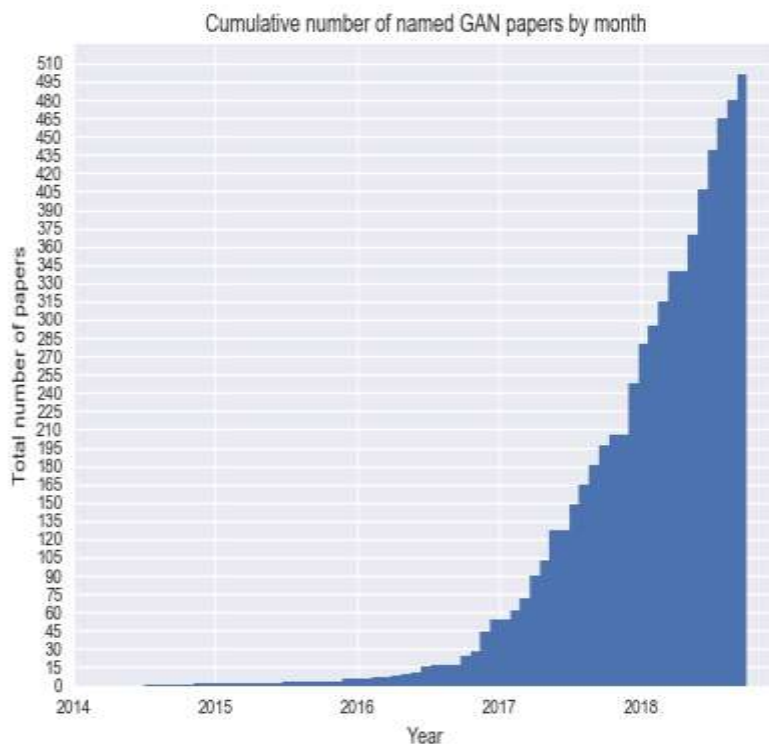


# Introdução

- Algumas aplicações de GANs:
  - Geração de exemplos para conjuntos de dados de imagem, fotografias de rostos humanos, fotografias realistas, visão facial frontal, novas poses humanas, personagens de animação;
  - Tradução de imagem para imagem, de texto para imagem, semântica de imagem para foto, de vestuário;
  - Edição de fotografia, mesclagem de fotos;
  - Fotos para emojis;
  - Envelhecimento facial;
  - Pintura interna de fotos;
  - Previsão de vídeo;
  - Geração de objetos 3D;

# Introdução

- Números de publicações e ilustração de uma GAN:



Which one is Computer generated?



Ledig, Christian, et al. "Photo-realistic single image super-resolution using a generative adversarial network." *arXiv preprint arXiv:1609.04802* (2016).

<https://github.com/hindupuravinash/the-gan-zoo>

# Modelos Generativos

- Modelos discriminativos se caracterizam por
  - Dado um  $\mathbf{x}$ , determina-se uma resposta  $y$  ou se estima a probabilidade  $p(y|\mathbf{x})$ ;
- Os modelos discriminativos apresentam limitações:
  - Não é possível modelar  $p(\mathbf{x})$ , portanto, não se pode gerar novos dados (amostrar  $p(\mathbf{x})$ );
- Modelos generativos, em geral, se caracterizam por:
  - Podem modelar  $p(\mathbf{x})$ ;
  - Podem gerar novos dados.

# Modelos Generativos

- Modelos generativos estimam o processo probabilístico que gera um conjunto de observações  $\mathcal{D}$ :
  - $\mathcal{D} = \{\mathbf{x}^i, \mathbf{y}^i\}$ ,  $i=1, \dots, n$ ; modelos generativos supervisionados aprendem distribuição de probabilidade conjunta  $p(\mathbf{x}^i, \mathbf{y}^i)$ , frequentemente para calcular  $p(\mathbf{y}^i | \mathbf{x}^i)$ ;
  - $\mathcal{D} = \{\mathbf{x}^i\}$ ,  $i=1, \dots, n$ ; modelos generativos não-supervisionados aprendem a distribuição de  $\mathcal{D}$  para agrupamento ou amostragem de duas maneiras:
    - Por estimativa direta de  $p(\mathbf{x}^i)$ ;
    - Introdução de variável latente  $\mathbf{y}^i$  e estimativa de  $p(\mathbf{x}^i, \mathbf{y}^i)$ ;

# Modelos Generativos

- Modelos generativos estimam o processo probabilístico que gera um conjunto de observações  $\mathcal{D}$ :
  - Escolhe-se uma família parametrizada  $p(\mathbf{x} \mid \theta)$  e aprende-se  $\theta$  maximizando a log-verossimilhança:

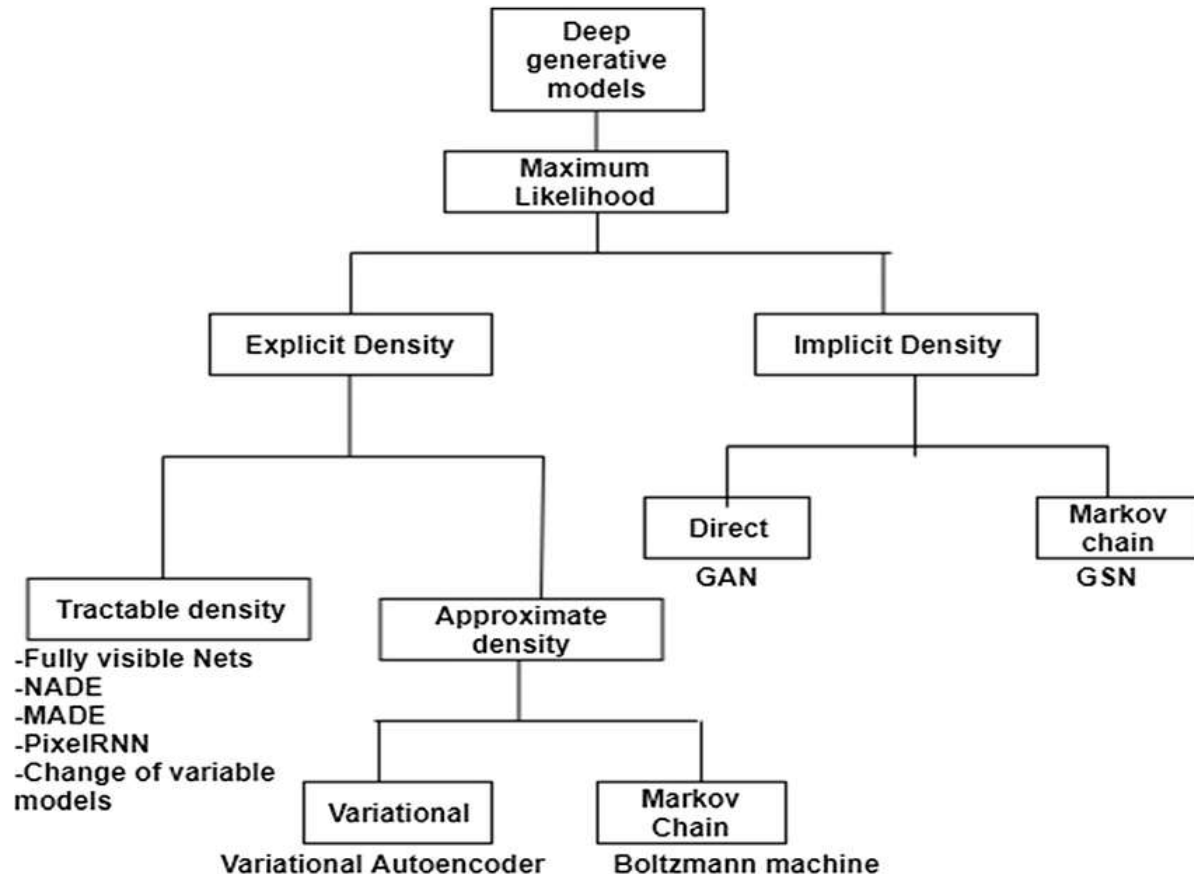
$$\theta^* = \arg \max_{\theta} \sum_{i=1}^n \log p(\mathbf{x}^i \mid \theta).$$

- Modelos com variáveis latentes: Define-se uma distribuição conjunta  $p(\mathbf{x}, \mathbf{y} \mid \theta)$  e aprende-se  $\theta$  maximizando a verossimilhança log-marginal:

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^n \log \int p(\mathbf{x}^i, \mathbf{z}^i \mid \theta) d\mathbf{z}.$$

# Modelos Generativos

- Opções para estimação função de densidade:
  - Densidade explícita;
  - Densidade implícita;
- Nos modelos generativos implícitos pode-se avaliar a qualidade das amostras, logo calcula-se seu gradiente em relação aos parâmetros da rede e estes são atualizados;






# Redes Adversárias Generativas (GANs)


- Redes adversárias generativas (GANs) (Goodfellow et al., 2014) são baseadas em um suposto cenário de jogo no qual a rede geradora deve competir contra um adversário:
  - Uma rede geradora produz amostras;
  - A rede discriminadora (adversária) tenta distinguir amostras de dados de treinamento e amostras vindas do gerador;
  - O discriminador estima uma probabilidade que uma amostra seja um exemplo de treinamento real em vez de gerada pelo modelo;
- Redes adversárias generativas (GANs):
  - Generativa porque aprende a distribuição subjacente dos dados;
  - Adversária por ser formada por duas redes concorrentes;
  - Redes por empregar redes neurais profundas.

# Redes Adversárias Generativas (GANs)

- As *Generative Adversarial Networks* (GANs) visa aproximar duas distribuições para gerar uma saída realista e de qualidade:
  - A distribuição de probabilidade de um gerador de instâncias,  $P_G(\cdot)$ ;
  - A distribuição de probabilidade das imagens reais,  $P_{\text{data}}(\cdot)$ ;
- A similaridade entre as duas distribuições é calculada por:
  - Divergência de Kullback-Leibler (KLD): Métrica não simétrica que afere entropia relativa ou diferença na informação de duas distribuições;
  - KLD mede a distância entre duas distribuições de dados;



Original Gaussian PDF's



KL Area to be Integrated

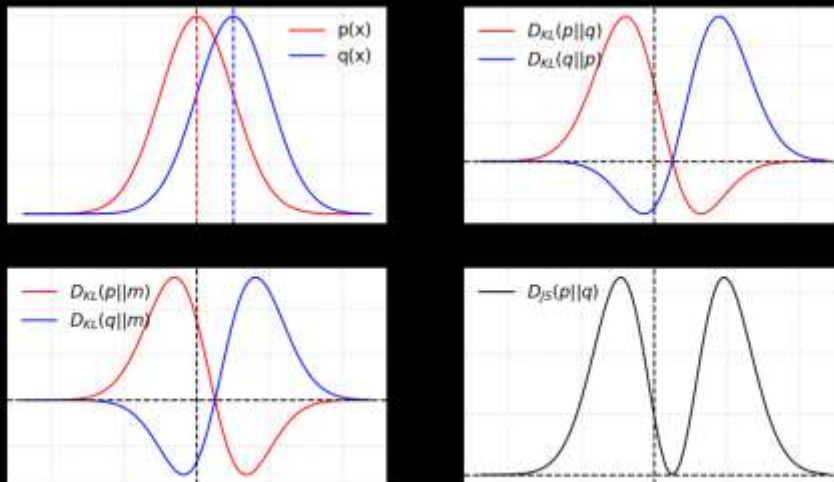
$$D_{KL}(P||Q)$$

$$KL(P||Q) = \sum p(x) \log \frac{p(x)}{q(x)}$$

$$KL(Q||P) = \sum q(x) \log \frac{q(x)}{p(x)}$$

# Redes Adversárias Generativas (GANs)

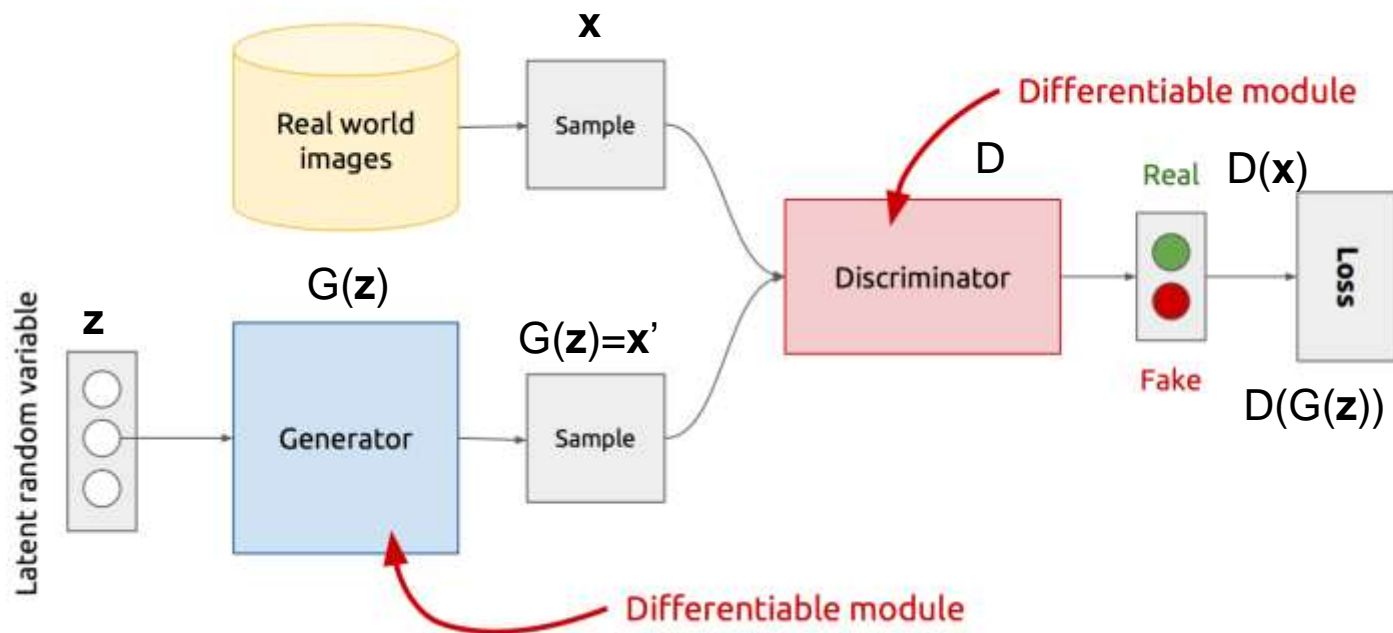
- ... a similaridade entre as duas distribuições é calculada por:
  - Divergência de Jensen-Shannon (JSD): Método de medir a similaridade entre duas pdfs, é simétrica e sempre tem um valor finito,
    - A raiz quadrada da JSD é chamada de distância de Jensen-Shannon;
  - Por ser simétrica, JSD compara pdfs, independentemente de qual distribuição é referência e qual é a ser comparada;  
$$\text{JSD}(P \parallel Q) = \frac{1}{2}D(P \parallel M) + \frac{1}{2}D(Q \parallel M), \quad \text{onde } M = (P+Q)/2 \text{ e } D=\text{KLD};$$



- Distribuições gaussianas:
  - $\mathbb{N}_1(\mu=0, \sigma=1) = p(\cdot)$ ;
  - $\mathbb{N}_2(\mu=1, \sigma=1) = q(\cdot)$ ;
  - Média:  $M = (\mathbb{N}_1 + \mathbb{N}_2)/2$ ;
- KLD é assimétrica mas JSD é simétrica;

# Redes Adversárias Generativas (GANs)

- Arquitetura geral de uma GAN:
  - $z$  é um ruído aleatório (Gaussiano/Uniforme) que é entendido como a representação latente da imagem;



# Redes Adversárias Generativas (GANs)

- Treinamento de uma GAN:
  - Gerador  $G$ : Entrada  $\mathbf{z}$  e saída  $G(\mathbf{z}) = \mathbf{x}'$ ;
    - Dada uma distribuição a priori  $P_{\text{prior}}(\mathbf{z})$ , uma distribuição de probabilidade  $P_G(\mathbf{z})$  é determinada pela função  $G$ ;
  - Discriminador  $D$ : Entradas  $\mathbf{x}$  e  $G(\mathbf{z}) = \mathbf{x}'$ , e saída escalar,  $D(\cdot)$ ;
    - A saída avalia a diferença entre  $P_G(\mathbf{z})$  e  $P_{\text{data}}(\mathbf{x})$ ;
- Define-se uma função de custo  $V(G, D)$  para  $D$  determinar diferença entre  $P_{\text{data}}$  de  $P_G$ :  $G^* = \arg \min_G \max_D V(G, D)$ ,
  - A distribuição  $G$  pode ser alterada e não apenas seus parâmetros;
- Formulação como um jogo MinMax:
  - O discriminador visa maximizar sua recompensa enquanto o gerador busca minimizar a recompensa do discriminador;

# Redes Adversárias Generativas (GANs)

- Formulação de jogo MinMax (Jensen–Shannon divergence - JSD):
  - Aproximação inspirada na teoria dos jogos:
$$\text{Min}_G \text{Max}_D V(G,D) = \underbrace{E_{\mathbf{x} \sim P_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})]}_{\text{verossimilhança de dados reais}} + \underbrace{E_{\mathbf{z} \sim P_G(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]}_{\text{verossimilhança de dados gerados}}$$
  - Discriminador D (saída de 0 a 1) ajusta pesos para maximizar V:
    - Deseja-se que  $D(\mathbf{x})$  tenda a um e  $D(G(\mathbf{z}))$  tenda a zero;
  - Gerador G (saída de imagem) procura confundir o discriminador D, a fim de minimizar V:
    - Deseja-se que  $D(\mathbf{x})$  tenda a zero e  $D(G(\mathbf{z}))$  tenda a um;
- Lembrando que  $\log(1) = 0$ ;  $\log(0,1) = -1$ ;  $\log(0) = -\infty$ ;
- O equilíbrio de Nash desse jogo em particular é obtido em:
  - $P_{\text{data}}(\mathbf{x}) = P_G(\mathbf{z})$ ;
  - $D(\mathbf{x}) = 1/2, \forall \mathbf{x}$ ;

# Redes Adversárias Generativas (GANs)

- Formulação a função de custo  $V(G,D)$  definida, alterna-se entre:
  - Elevação do gradiente para o discriminador :

$$\text{Max}_D V(G,D) = E_{\mathbf{x} \sim P_{\text{data}}(\mathbf{x})}[\log D(\mathbf{x})] + E_{\mathbf{z} \sim P_G(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))]$$


- Redução do gradiente para o gerador :

$$\text{Min}_G V(G,D) = E_{\mathbf{z} \sim P_G(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))]$$

- Uma amostra gerada ruim tem  $D(G(\mathbf{z})) \approx 0$  e  $D(\mathbf{x}) \approx 1$ , situação que geralmente ocorre no início do treinamento, logo o discriminador tem previsão próxima a zero, portanto, sua derivada é nula (gradiente que desaparece);

# Redes Adversárias Generativas (GANs)

- Nova função de custo para o gerador:
  - $\text{Min}_G V(G,D) = E_{z \sim P_G(x)} [-\log D(G(z))]$





# Redes Adversárias Generativas (GANs)

## • Aprendendo D

- Inicialize  $\theta_d$  para D e  $\theta_g$  para G
- Repita  $K$  vezes
- Amostre  $m$  exemplos  $\{\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^m\}$  da distribuição de dados  $P_{\text{data}}(\mathbf{x})$ ;
- Amostre  $m$  exemplos de ruído  $\{\mathbf{z}^1, \dots, \mathbf{z}^m\}$  da distribuição a priori dos dados  $P_{\text{prior}}(\mathbf{z})$ ;
- Obtenha os dados gerados  $\{\mathbf{x}^{*1}, \dots, \mathbf{x}^{*m}\}$ ,  $\mathbf{x}^{*i} = G(\mathbf{z}^i)$ ,  $i = 1, \dots, m$ ;
- Atualize os parâmetros do discriminador  $\theta_d$  para maximização
- $V' \approx 1/m \sum_{i=1, \dots, m} \log D(\mathbf{x}^i) + 1/m \sum_{i=1, \dots, m} -\log(D(\mathbf{x}^{*i}))$  ;
- $\theta_d \leftarrow \theta_d + \eta \nabla_{\theta_d} V'(\theta_d)$  (gradiente ascendente)
- Fim-do-Repita


# Redes Adversárias Generativas (GANs)

- Aprendendo G

- Amostre  $m$  novos exemplos de ruído  $\{\mathbf{z}^1, \dots, \mathbf{z}^m\}$ ; dos dados da distribuição a priori  $P_{\text{prior}}(\mathbf{z})$ ;
- Obtenha os dados gerados  $\{\mathbf{x}^{*1}, \dots, \mathbf{x}^{*m}\}$ ,  $\mathbf{x}^{*i} = G(\mathbf{z}^i)$ ,  $i = 1, \dots, m$ ;
- Atualize os parâmetros do gerador  $\theta_g$  para minimização
- $V' \approx 1/m \sum_{i=1, \dots, m} [-\log D(\mathbf{x}^{*i})]$  ;
- $\theta_g \leftarrow \theta_g - \eta \nabla V'(\theta_g)$  (gradiente descendente)

# Redes Adversárias Generativas (GANs)

- Visualização do aprendizado de D e G:
  - $\text{Max}_D V(G,D)$  e  $\text{Min}_G V(G,D)$ ;



# Redes Adversárias Generativas (GANs)

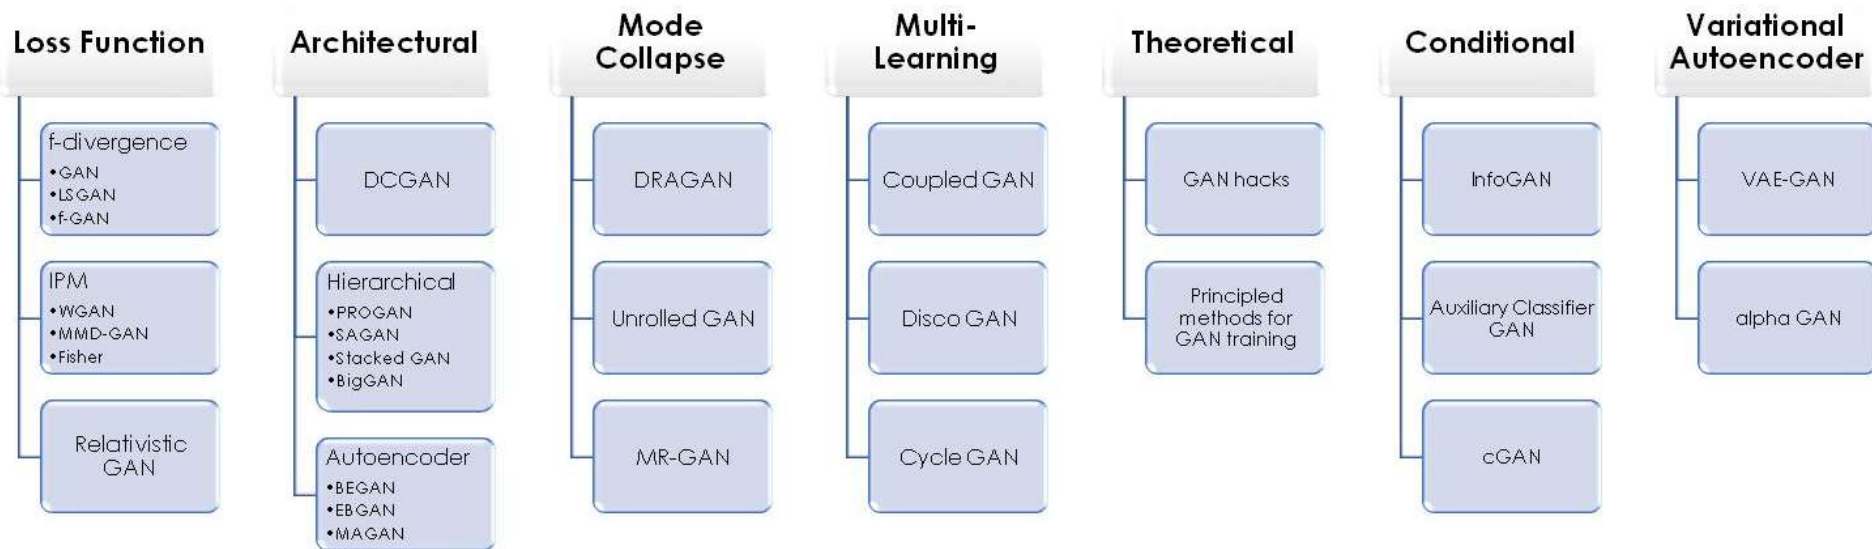
- Métricas de desempenho:
  - Acuracidade:  $A = (VN + VP)/(VN+FN+FP+VP)$ ;
  - Precisão:  $P = VP/(VP+FP)$ ;
  - Revocação (*Recall*):  $R = TP/(TP+FN)$ ;
  - F1-Score é a média harmônica entre precisão e revocação:  
 $F1 = 2[(P \cdot R)/(P+R)]$ ;
  - Curva característica operacional do receptor (ROC): Plota o gráfico entre a taxa de TP (sensibilidade) e a taxa de FP (1-especificidade) com respeito a um limiar de aceitação de um exemplo como verdadeiro positivo;
  - Área sob a curva ROC (AUC): Permite comparar diferentes curvas ROC;

# Redes Adversárias Generativas (GANs)

- Algumas limitações de GAN:
  - Gradiente que desaparece para um discriminador bom demais;
  - Ausência de convergência pois o gerador e o discriminador oscilam sem atingir o equilíbrio;
  - Colapso da distribuição do gerador que é reduzida a um pequeno conjunto de exemplos;
  - Queda da distribuição do gerador que não cobre totalmente a distribuição de dados;
- Tratamentos das limitações:
  - Mudança de objetivos: Emprego de objetivo heurístico que não satura, custo de máxima verossimilhança, etc;
  - Discriminador limitado: restringir a capacidade do discriminador;
  - Agendar aprendizagem: balancear aprendizagem de  $D_{\theta_d}$  e  $G_{\theta_g}$ ;

# GAN – Extensões

- Sete diferentes perspectivas para extensões:
  - Função de perda, arquitetura, colapso de modo, multi-aprendizagem, teórico, condicional, auto-encoder variacional;




# GAN – Extensões

- (a) GAN Vanilla é o modelo GAN básico:

- D é o Discriminador e G é o gerador;



- Seja um G pré-treinado e uma saída  $\mathbf{x}$ ;
  - Otimize  $\min_{\mathbf{z}} \|\mathbf{x} - G(\mathbf{z})\|^2$
  - Treinamento lento;



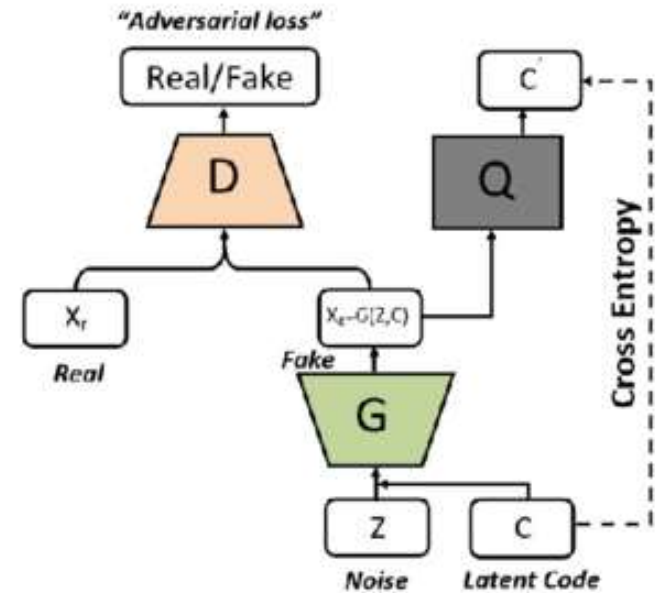
(a) GAN

# GAN – Extensões

- (b) Na InfoGAN, a função objetivo aprende representações interpretáveis e significativas maximizando informação mútua entre subconjunto fixo de variáveis de ruído e as observações:

$$\text{Min}_{G,Q} \text{Max}_D V(G,D,Q) = V(G,D) - \lambda L_I(G,Q)$$

- Q é distribuição auxiliar próxima da posterior;  $L_I$  é limite inferior variacional da informação mútua entre o código latente e as observações;
- Sua implementação compreende outra camada totalmente conectada aos parâmetros de saída para a distribuição




(b) InfoGAN



# GAN – Extensões


- (d) GAN condicional (cGAN) gera condicionalmente os padrões de saída;
- Nas cGANs, gerador e discriminador estão condicionados a informação auxiliar (rótulos de classe ou dados),
  - O modelo pode aprender mapeamento multimodal de entradas para saídas devido às informações contextuais;
  - A maioria das variantes GAN pode ser modificada para incluir cGAN;
  - cGAN faz G criar amostras específicas, corrigindo assim o problema de colapso do modo;



(d) CGAN

# GAN – Extensões

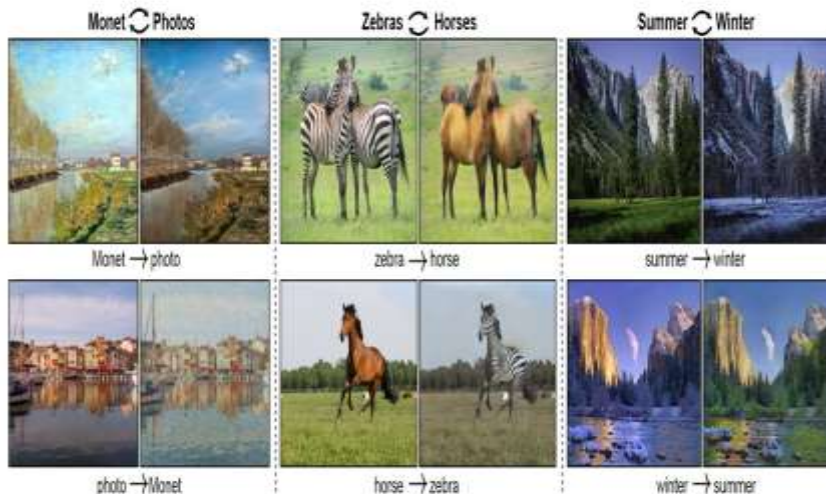
- (e) GAN com Classificador Auxiliar (ACGAN), como o cGAN, tem gerador que recebe um ponto no espaço latente e um rótulo, porém, seu discriminador não recebe a informação de contexto;
- Modelo do Gerador:
  - Entrada: Ponto aleatório do espaço latente e o rótulo da categoria;
  - Saída: Imagem gerada;
- Modelo de discriminador:
  - Entrada: Imagem;
  - Saída: Probabilidade de que a imagem



(e) ACGAN

# GAN - Aplicações


- Visão computacional:
  - Geração de imagens (CGAN, DCGAN);
  - Tradução de imagem (Ciclo GAN);
  - Super-resolução (SRGAN, ProGAN);
  - Envelhecimento facial (StarGAN, AgeC-GAN);
  - Síntese de textura (Estilo GAN);
  - Texto para imagens (StackGAN, PSGAN);
  - Detecção de objetos (GAN percentual);



# GAN - Aplicações

- Geração de dados:
  - Aumento dos conjuntos de dados de treinamento;
  - Criação de novos dados pelo gerador da GAN;
  - Uso mais frequente em imagens que em dados tabulares;


Aumento de dados  
Para o YOLOv4




# GAN - Aplicações

- Séries temporais:
  - GANs condicionais permite uso de redes neurais recorrentes para gerar dados de séries temporais;
  - Aplicações: modelagem econômica, previsão de estoque, previsão de mortalidade, valor em risco, projeções financeiras, etc.

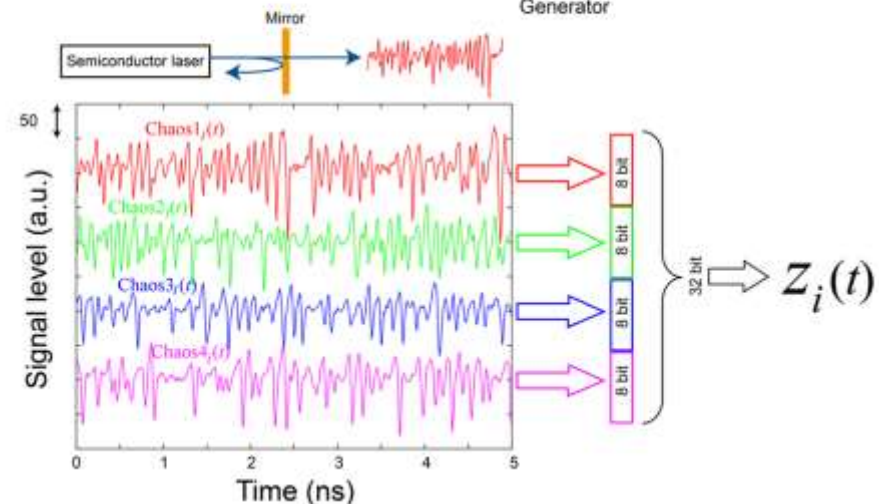
a



b



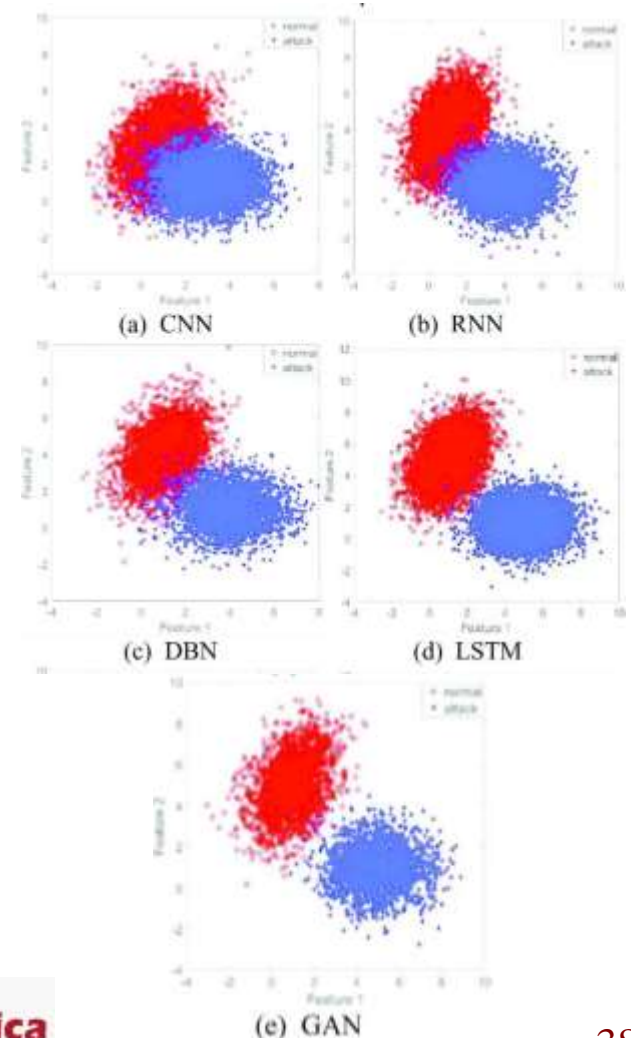
c





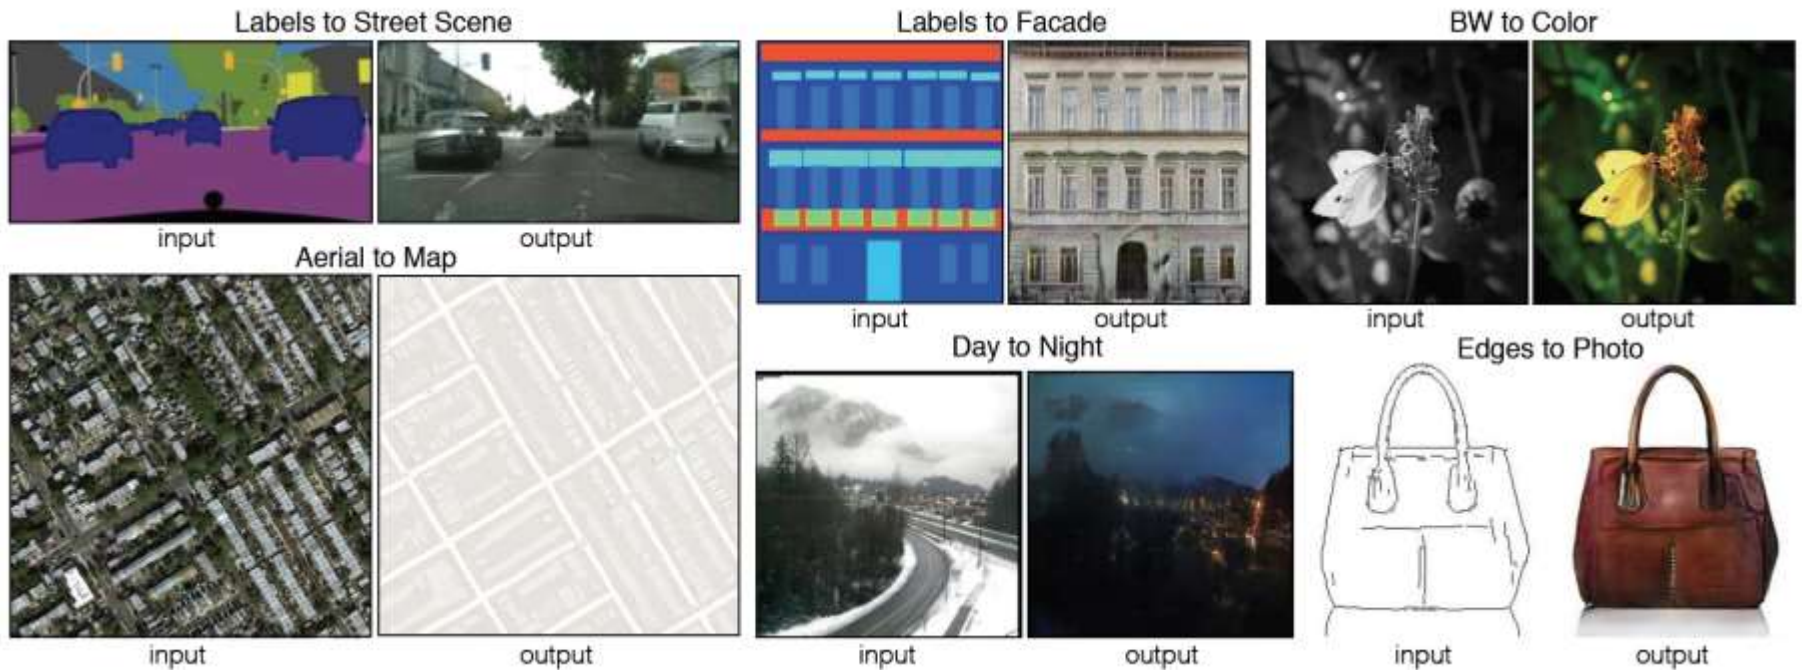
# GAN - Aplicações

- Detecção de anomalia:
  - Identificação de itens raros ou eventos suspeitos com respeito à maioria dos dados;
  - Exemplo: Simulação de tráfego em rede local de computadores que apresenta tráfego normal e comportamentos anormais;



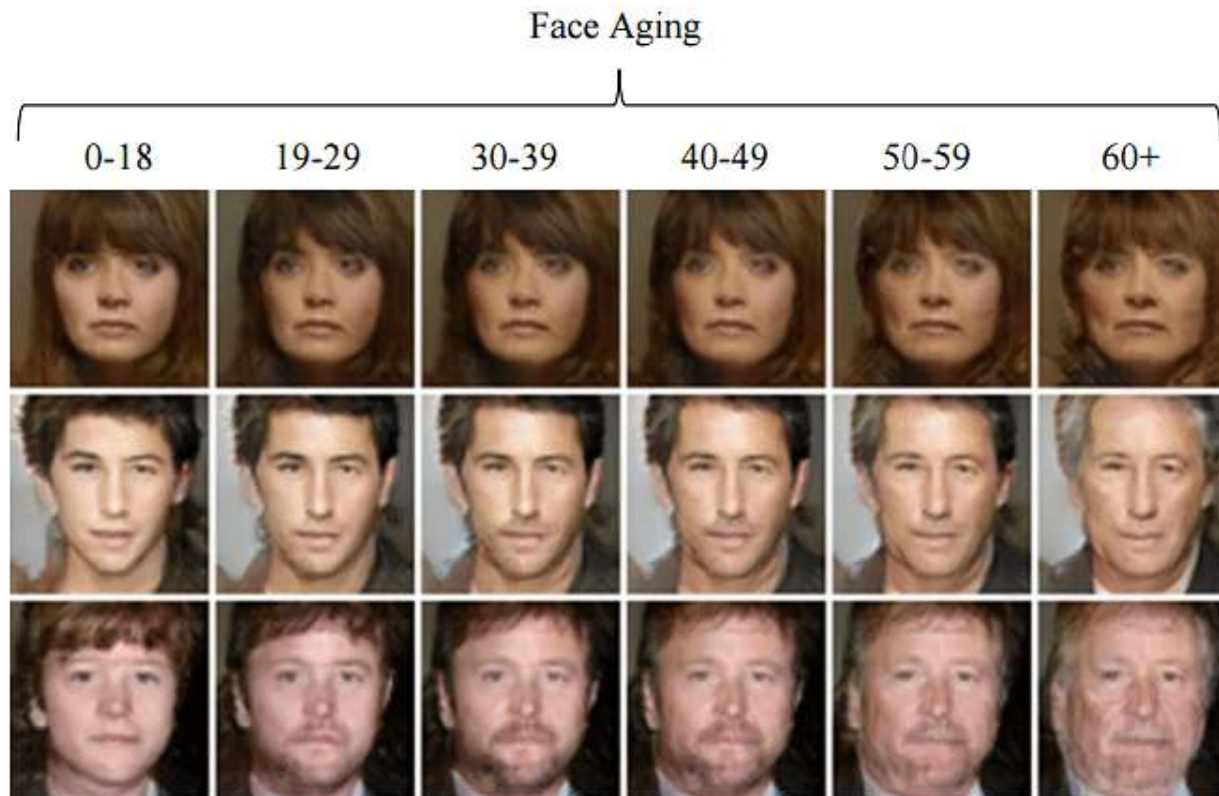
# GAN - Aplicações

- Tradução de imagem para imagem:
  - DCGAN tem treino condicionado às imagens do domínio fonte;



# GAN - Aplicações

- Envelhecimento facial:
  - GANs condicional pode renderizar rosto envelhecido;
  - Pode ser útil na busca de crianças desaparecidas;





# Softwares

- GAN Lab: <https://poloclub.github.io/ganlab/>
- TF-GAN: <https://github.com/tensorflow/gan>
- Keras GAN: [https://github.com/keras-team/keras-contrib/tree/master/examples/improved\\_wgan](https://github.com/keras-team/keras-contrib/tree/master/examples/improved_wgan)
- DCGAN TensorFlow: <https://github.com/carpedm20/DCGAN-tensorflow>
- Deep Convolutional GANs: <https://github.com/carpedm20/DCGAN-tensorflow>
- Wasserstein GAN: <https://github.com/martinarjovsky/WassersteinGAN>

# Referências

- Aggarwal, A., Mittal, M., & Battineni, G. (2021). Generative adversarial network: An overview of theory and applications. *International Journal of Information Management Data Insights*, 1(1).
- Asimopoulos, D. C., Nitsiou, M., Lazaridis, L., & Fragulis, G. F. (2022). Generative Adversarial Networks: a systematic review and applications. In *SHS Web of Conferences* (Vol. 139, p. 03012). EDP Sciences.
- Dash, A., Ye, J., & Wang, G. (2021). A review of Generative Adversarial Networks (GANs) and its applications in a wide variety of disciplines--From Medical to Remote Sensing. *arXiv preprint arXiv:2110.01442*.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial nets. In *Advances in Neural Information Processing Systems*, 27: 2672–2680.
- Hong, Y., Hwang, U., Yoo, J., & Yoon, S. (2019). How generative adversarial networks and their variants work: An overview. *ACM Computing Surveys*, 52(1), 1-43.
- Jabbar, A., Li, X., & Omar, B. (2021). A survey on generative adversarial networks: Variants, applications, and training. *ACM Computing Surveys*, 54(8), 1-49.
- Li, Y., Wang, Q., Zhang, J., Hu, L., & Ouyang, W. (2021). The theoretical research of generative adversarial networks: an overview. *Neurocomputing*, 435, 26-41.