



Mapas Auto-organizáveis - Extensões (*Self-Organizing Maps* - SOM)

Aluizio Fausto Ribeiro Araújo
Universidade Federal de Pernambuco
Centro de Informática - CIn
Departamento de Sistemas da Computação
aluizioa@cin.ufpe.br



Conteúdo

- Introdução
- *Grid* Diferente do SOM
- Ponderação no cálculo de distâncias
- Modelo estocástico
- *Kernel* SOM
- Modelo hierárquico
- Estrutura variante no tempo

Introdução

- Objetivos:
 - Apresentar diferenças e contribuições de alguns mapas derivados do SOM (*Self-Organizing Map*);
 - Atuar nas limitações encontradas na literatura;

Introdução

- Algumas limitações do SOM:
 - A pré-definição da estrutura limita o mapeamento resultante,
 - Número fixo de nodos;
 - Conexões entre nodos pré-definidas;
 - Tipos limitados de topologia dos mapas,
 - Poucos tipos de vizinhanças;
 - Emprego de distância euclideana,
 - Mesma importância das dimensões;
 - Distâncias que podem perder capacidade de discriminação;
 - Processamento restrito a uma camada,
 - Dificuldades em perceber diferenças sutis intracategóricas;

Grid Diferente


Hyperbolic Self-Organizing Maps – HSOM (2001)

- Contribuição:
 - O SOM possui uma vizinhança bastante restrita ajustada ao redor de um ponto sobre uma superfície euclidiana 2D;
 - Espaços hiperbólicos oferecem uma geometria cujo tamanho da vizinhança ao redor de um ponto cresce exponencialmente,
 - Permite novas configurações de vizinhança;

Grid Diferente

Hyperbolic Self-Organizing Maps (2001)

- Contribuição:
 - Plano hiperbólico:
 - Com triângulos:
 - Equiláteros;
 - Congruentes.



Grid Diferente

Hyperbolic Self-Organizing Maps (2001)

- Contribuição:

- Competição:

$$h_{rs}(n) = \exp(-d^2(r,s)/2\sigma^2)$$

$r \in N(s,t)$, vizinhança do vencedor

$$d = 2 \operatorname{arctanh} \left(\left| \frac{z_r - z_s}{1 - \bar{z}_s \cdot z_r} \right| \right)$$

onde para um *lattice* hiperbólico, cada nodo guarda um número complexo que identifica sua posição no modelo de Poincaré.

Grid Diferente

Hyperbolic Self-Organizing Maps (2001)

- Aplicação: categorização de textos;
 - Criação de relação semântica entre textos armazenados em uma base muito grande;
 - Elaboração de visualização de baixa dimensão;
 - Agrupamento de textos por categorias.

Ponderação no Cálculo de Distâncias

Parameterized Self-organizing Maps – PSOM (1998)

- Contribuição:
 - Muitos modelos de redes neurais necessitam de centenas ou milhares de instâncias e iterações para treinamento;
 - Há casos nos quais a criação de uma base de dados requer muito esforço;
 - PSOM possui ampla capacidade de generalização em base de dados pequenas, além de ser rápido para treinar.

Ponderação no Cálculo de Distâncias

Parameterized Self-organizing Maps – PSOM (1998)

- Competição:
 - Pode seleccionar subespaços dos dados de entrada;
 - **p** selecciona diferente subespaços;
 - Pondera os componentes das distâncias;

$$dist(x, x') = \sum_{k=1}^d p_k (x_k - x'_k)^2$$

Ponderação no Cálculo de Distâncias

Parameterized Self-organizing Maps – PSOM (1998)

- Aplicação:
 - Controle de robôs articulados, por exemplo, mão robótica.

Modelo Estocástico

Bayesian Self-Organising Map – BSOM (2001)

- Teorema de Bayes:
 - Modelagem por inferência estatística;
 - $\Pr(A)$ e $\Pr(B)$ são as probabilidades a priori de A e B ;
 - $\Pr(B|A)$ e $\Pr(A|B)$ são as probabilidades a posteriori de B condicional a A e de A condicional a B respectivamente;

$$\Pr(A|B) = \frac{\Pr(B|A) \Pr(A)}{\Pr(B)}$$

Modelo Estocástico

Bayesian Self-Organising Map – BSOM (2001)

- Contribuição:
 - Em reconhecimento de padrões é importante que haja uma estimativa precisa da distribuição dos dados;
 - Mistura de distribuições oferece uma abordagem mais flexível para estimar a densidade dos dados;
 - BSOM possibilita a mistura de gaussianas;

Modelo Estocástico

Bayesian Self-Organising Map – BSOM (2001)

- Competição:
 - A métrica para determinar o vencedor é substituída por uma regra baseada na probabilidade a posteriori do teorema de Bayes,
 - O vencedor tem maior probabilidade a posteriori;
- Adaptação:
 - É proporcional à probabilidade a posteriori estimada do nodo vencedor e de seus vizinhos;

Modelo Estocástico

Bayesian Self-Organising Map – BSOM (2001)

- Aplicações:
 - Aprendizagem de mistura de gaussianas;
 - Reconhecimento de padrões;
 - Agrupamento.

Kernel SOM

- Uma função *kernel* é definida como $\kappa: X \times X \in \mathbb{R}$, onde X é o espaço de entrada;
- Mais especificamente, a função de *kernel* é definida por um produto interno: $\kappa(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x}) \cdot \phi(\mathbf{y})$, onde $\phi(\cdot)$ é uma função mapeadora usualmente não-linear e desconhecida,
 - $\phi : X \rightarrow F$, onde este é um espaço de características de produto interno de alta dimensão;
- Todas as operações são definidas em termos da função de kernel ao invés da função de mapeamento

Kernel SOM

- Função objetivo: entropia conjunta das saídas da função de *kernel*:


$$H(Y_i) = - \int_{-\infty}^{\infty} p_{Y_i}(y_i) \log p_{Y_i}(y_i) dy_i; \text{ onde } y_i = \kappa(\mathbf{x}, \mathbf{w}_i, \sigma_i)$$

- Função de *kernel* (distribuição gamma incompleta):

$$k(\mathbf{x}, \mathbf{w}_i, \sigma_i) = \frac{1}{\Gamma(\frac{m}{2})} \Gamma\left(\frac{m}{2}, \frac{\|\mathbf{x} - \mathbf{w}_i\|^2}{2\sigma_i^2}\right), i = 1, 2, \dots, l$$

Kernel SOM

- Função de *kernel* (distribuição gamma incompleta):



Kernel SOM

- Determinação do vencedor:

$$i(\mathbf{x}) = \arg \min_j y_i = \arg \min_j k(\mathbf{x}, \mathbf{w}_i, \sigma_i)$$

- Função de vizinhança:

$$h_{j,i(\mathbf{x})} = \exp\left(-\frac{\|\mathbf{x} - \mathbf{w}_j\|^2}{2\sigma^2}\right), \quad j \in A$$

Kernel SOM

- Ajustes do peso e da dispersão:

$$\mathbf{w}_j(n+1) = \begin{cases} \mathbf{w}_j(n) + \frac{\eta_w h_{j,i(\mathbf{x})}}{\sigma_j^2} (\mathbf{x}(n) - \mathbf{w}_j(n)), & j \in A \\ \mathbf{w}_j(n), & \text{de outra forma} \end{cases}$$

$$\sigma_j(n+1) = \begin{cases} \sigma_j(n) + \frac{\eta_\sigma h_{j,i(\mathbf{x})}}{\sigma_j(n)} \left[\frac{\|(\mathbf{x}(n) - \mathbf{w}_j(n))\|^2}{m\sigma_j^2(n)} - 1 \right], & j \in A \\ \sigma_j(n), & \text{de outra forma} \end{cases}$$

Kernel SOM

Algoritmo de aprendizagem KSOM:

- Inicialize aleatoriamente os pesos $\mathbf{w}_j(0)$ com valores pequenos;
- Enquanto $H(Y_i)$ não convergir:
- Apresente a entrada $\mathbf{x}$;
- Encontre o vencedor $i(\mathbf{x})$;
- Atualize os pesos e as dispersões;
- Fim-do-enquanto;

Modelo Hierárquico

Growing Grid (1995)

- Contribuição:
 - Varia a tamanho da rede durante o treinamento;
- Arquitetura:
 - Semelhante ao SOM, mas com adição de linha ou coluna na grade;
- Aplicações:
 - Geração de mapas topológicos, visualização de dados.

Modelo Hierárquico

Growing Hierarchical Self-Organizing Map –
GHSOM (2000)

- Contribuição:
 - Um SOM hierárquico com topologia dinâmica;
 - O tamanho das sub-redes e a profundidade da hierarquia são determinados durante o processo de treinamento não-supervisionado.

Modelo Hierárquico


Growing Hierarchical Self-Organizing Map (2000)

- Estrutura:
 - Múltiplas camadas organizadas de forma hierárquica;
 - Cada camada possui uma quantidade independente de redes SOMs;
 - A primeira camada contém uma rede SOM apenas;
 - A rede SOM empregada é uma versão cujo crescimento acontece durante o processo de treinamento.

Modelo Hierárquico

Growing Hierarchical Self-Organizing Map (2000)

- Arquitetura:



Modelo Hierárquico

Growing Hierarchical Self-organizing Map (2000)

- Aplicação:
 - Recuperação da informação;
 - Organização de documentos;

Estrutura Variante no Tempo

Growing Neural Gas (GNG) (Fritzke, 1995)

- *Growing Neural Gas* (GNG) pode ser vista como:
 - Uma variante do *Growing Cell Structures* (GCS) sem preservação de topologia, ou
 - Uma variante incremental do *Topology Representing Networks* (TRN);
- Proposta:
 - Geração de grafo que represente a topologia da variedade (*manifold*) do espaço de entrada (aprendizagem de topologia);
 - A dimensionalidade do grafo depende da distribuição dos dados do espaço de entrada;

Estrutura Variante no Tempo

Growing Neural Gas (GNG)

- Regra de Aprendizagem:
 - As idades das conexões são usadas para remove-las quando se tornam inválidas durante o processo de aprendizagem (como na TRN);
 - Uma variável de erro associada a cada nodo é empregada para determinar onde inserir novos nodos (como na GCS);

Estrutura Variante no Tempo


Learning Rule:

1. Start the map with two units s_a and s_b at random positions in $\mathbf{R}^n$

Estrutura Variante no Tempo


Learning Rule:

2. Generate an input signal ξ according to $P(\xi)$



Estrutura Variante no Tempo

Learning Rule:



2. Generate an input signal ξ according to $P(\xi)$


3. Determine the units s_1 e s_2 nearest to ξ

$$\| \mathbf{w}_{s_1} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A \quad \text{and}$$

$$\| \mathbf{w}_{s_2} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A - \{s_1\}$$

Estrutura Variante no Tempo

Learning Rule:



2. Generate an input signal ξ according to $P(\xi)$

3. Determine the units s_1 e s_2 nearest to ξ


$$\| \mathbf{w}_{s_1} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A \quad \text{and}$$

$$\| \mathbf{w}_{s_2} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A - \{s_1\}$$

Competition

Estrutura Variante no Tempo


Learning Rule:



2. Generate an input signal ξ according to $P(\xi)$
3. Determine the units s_1 e s_2 nearest to ξ
$$\| \mathbf{w}_{s_1} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A \quad \text{and}$$
$$\| \mathbf{w}_{s_2} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A - \{s_1\}$$
4. If it does not already exist, insert a connection between s_1 and s_2 . In any case, set the age of the connection between s_1 and s_2 to zero

Estrutura Variante no Tempo

Learning Rule:




2. Generate an input signal ξ according to $P(\xi)$
3. Determine the units s_1 e s_2 nearest to ξ
$$\| \mathbf{w}_{s_1} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A \quad \text{and}$$
$$\| \mathbf{w}_{s_2} - \xi \| \leq \| \mathbf{w}_{s_i} - \xi \| \quad \forall s_i \in A - \{s_1\}$$
4. If it does not already exist, insert a connection between s_1 and s_2 . In any case, set the age of the connection between s_1 and s_2 to zero

Topology Learning

Estrutura Variante no Tempo

Learning Rule:




2. Generate an input signal ξ according to $P(\xi)$
3. Determine the units s_1 e s_2 nearest to ξ
$$\|\mathbf{w}_{s_1} - \xi\| \leq \|\mathbf{w}_{s_i} - \xi\| \quad \forall s_i \in A \quad \text{and}$$
$$\|\mathbf{w}_{s_2} - \xi\| \leq \|\mathbf{w}_{s_i} - \xi\| \quad \forall s_i \in A - \{s_1\}$$
4. If it does not already exist, insert a connection between s_1 and s_2 . In any case, set the age of the connection between s_1 and s_2 to zero
5. Move s_1 and its direct topological neighbors towards ξ .

$$\Delta \mathbf{w}_{s_1} = \varepsilon_b (\xi - \mathbf{w}_{s_1})$$

$$\Delta \mathbf{w}_{s_i} = \varepsilon_n (\xi - \mathbf{w}_{s_i}) \quad \forall s_i \in N_{s_1},$$

Estrutura Variante no Tempo

Learning Rule:



2. Generate an input signal ξ according to $P(\xi)$
3. Determine the units s_1 e s_2 nearest to ξ
$$\|\mathbf{w}_{s_1} - \xi\| \leq \|\mathbf{w}_{s_i} - \xi\| \quad \forall s_i \in A \quad \text{and}$$
$$\|\mathbf{w}_{s_2} - \xi\| \leq \|\mathbf{w}_{s_i} - \xi\| \quad \forall s_i \in A - \{s_1\}$$
4. If it does not already exist, insert a connection between s_1 and s_2 . In any case, set the age of the connection between s_1 and s_2 to zero
5. Move s_1 and its direct topological neighbors towards ξ .

$$\Delta \mathbf{w}_{s_1} = \varepsilon_b (\xi - \mathbf{w}_{s_1})$$

$$\Delta \mathbf{w}_{s_i} = \varepsilon_n (\xi - \mathbf{w}_{s_i}) \quad \forall s_i \in N_{s_1},$$


Competition and Collaboration

Estrutura Variante no Tempo

Learning Rule:

6. Add ΔE_{s_1} to the s_1 local error variable

$$\Delta E_{s_1} = \| \mathbf{w}_{s_1} - \xi \|^2$$




Estrutura Variante no Tempo

Learning Rule:


6. Add ΔE_{s_1} to the s_1 local error variable

$$\Delta E_{s_1} = \| \mathbf{w}_{s_1} - \xi \|^2$$



Estrutura Variante no Tempo

Learning Rule:




6. Add ΔE_{s_1} to the s_1 local error variable

$$\Delta E_{s_1} = \| \mathbf{w}_{s_1} - \xi \|^2$$

7. Increase by one the age of all edges emanating from s_1 .

Estrutura Variante no Tempo

Learning Rule:




6. Add ΔE_{s_1} to the s_1 local error variable

$$\Delta E_{s_1} = \| \mathbf{w}_{s_1} - \xi \|^2$$

7. Increase by one the age of all edges emanating from s_1 .

Estrutura Variante no Tempo

Learning Rule:




6. Add ΔE_{s_1} to the s_1 local error variable

$$\Delta E_{s_1} = \| \mathbf{w}_{s_1} - \xi \|^2$$

7. Increase by one the age of all edges emanating from s_1 .
8. Remove the connections with an age larger than a threshold (a_{max})

Estrutura Variante no Tempo

Learning Rule:




6. Add ΔE_{s_1} to the s_1 local error variable

$$\Delta E_{s_1} = \| \mathbf{w}_{s_1} - \xi \|^2$$

7. Increase by one the age of all edges emanating from s_1 .
8. Remove the connections with an age larger than a threshold (a_{max})
 - If this results in units having no emanating edges, remove them as well.

Estrutura Variante no Tempo

Learning Rule:




9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.

Growing Step

Estrutura Variante no Tempo


Learning Rule:



9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.
 - Determine the node s_q with the maximum accumulated error.

Estrutura Variante no Tempo


Learning Rule:



9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.
 - Determine the node s_q with the maximum accumulated error.

Estrutura Variante no Tempo


Learning Rule:



9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.
 - Determine the node s_q with the maximum accumulated error.
 - Determine the node s_f , topological neighbor of s_q , with the largest error variable.

Estrutura Variante no Tempo


Learning Rule:



9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.
 - Determine the node s_q with the maximum accumulated error.
 - Determine the node s_f , topological neighbor of s_q , with the largest error variable.

Estrutura Variante no Tempo


Learning Rule:



9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.
 - Determine the node s_q with the maximum accumulated error.
 - Determine the node s_f , topological neighbor of s_q , with the largest error variable.
 - Insert a new unit (s_r) between s_q and s_f .

Estrutura Variante no Tempo

Learning Rule:




9. If the number of input signals generated so far is an integer multiple of a parameter λ , insert a new unit as follows.
 - Determine the node s_q with the maximum accumulated error.
 - Determine the node s_f , topological neighbor of s_q , with the largest error variable.
 - Insert a new node (s_r) between s_q and s_f
 - Insert edges connecting the new node s_r with nodes s_q and s_f , and remove the original edge between s_q and s_f .


Comparação de Resultados

Mapeamentos criados pelo SOM e suas variantes:

SOM




a.)




b.)

TRN




a.)




b.)

GCS




a.)




b.)

GNG



a.)



b.)

Referências

- Dittenbach, M., Merkl, D., & Rauber, A. (2000). The growing hierarchical self-organizing map. *Proceedings of the IEEE-INNS-ENNS International Joint Conference on Neural Networks*, 6, 15-19.
- Fritzke, B. (1995a). A growing neural gas network learns topologies. *Advances in Neural Information Processing Systems*, 7: 625-632.
- Fritzke, B. (1996). Unsupervised ontogenetic networks. *Handbook of Neural Computation*, IOP Publishing and Oxford University Press.
- López-Rubio, E., Muñoz-Pérez, J., & Gómez-Ruiz, J. A. (2004). A principal components analysis self-organizing map. *Neural networks*, 17(2), 261-70.
- Ontrup, J., & Ritter, H. (2001). Hyperbolic Self-Organizing Maps for Semantic Navigation. *Proceedings of the 14th International Conference on Neural Information Processing Systems*, 1417–1424.

Referências

Villa, N., & Rossi, F. (2007). A comparison between dissimilarity SOM and kernel SOM for clustering the vertices of a graph. *Proceedings of the International Workshop on Self-Organizing Maps*.

Walter, J. A. (1998). PSOM Network : Learning with few examples. *PSOM network: learning with few examples. Proceedings. 1998 IEEE International Conference on Robotics and Automation*, 1-6.

Yin, H., & Allinson, N. M. (2001). Bayesian self-organising map for Gaussian mixtures. *IEE Proceedings-Vision, Image and Signal Processing*, 148(4), 234-240.