

Resumo: Autoencoders

joao.vmcardoso

1 Introdução

Autoencoders são modelos não supervisionados de aprendizado profundo que visam reconstruir os dados de entrada por meio de codificação em um espaço latente reduzido. São inspirados pela ideia de que grande parte do aprendizado em humanos e animais é não supervisionado (LeCun, Bengio, Hinton, 2015).

2 Definição e Estrutura

- Autoencoders são redes neurais que aprendem a reconstruir suas entradas.
- Contêm duas partes principais:
 - **Codificador (Encoder)**: mapeia a entrada para uma representação latente.
 - **Decodificador (Decoder)**: reconstrói a entrada a partir da representação latente.
- São capazes de capturar relações não lineares, ao contrário do PCA.

3 Propriedades e Limitações

- Compactam dados similares aos de treinamento.
- A saída é uma aproximação degradada da entrada.
- Têm risco de overfitting se forem grandes demais.

4 Comparação com PCA

- O PCA realiza transformação linear e ortogonal para redução de dimensionalidade.
- Autoencoders são generalizações não-lineares do PCA.
- PCA tem limitações para relações não-lineares e supõe que as direções de maior variância são mais informativas.

5 Autoencoder Empilhado (Stacked Autoencoder)

- Vários autoencoders são empilhados de forma hierárquica.
- A saída codificada de uma camada serve como entrada da próxima.
- Treinamento ocorre em duas fases:
 1. **Pré-treinamento não supervisionado:** uma camada por vez (greedy layer-wise).
 2. **Ajuste fino supervisionado:** toda a rede é treinada como um todo com rótulos.
- Força a rede a aprender uma representação útil e compacta.

6 Treinamento Greedy Layer-Wise

1. Treinar a primeira camada com dados não rotulados.
2. Fixar pesos e treinar a próxima camada com a saída da anterior.
3. Repetir até a última camada.
4. Inserir camada supervisionada no final e treinar.
5. Ajustar todos os pesos finamente com backpropagation.

6.1 Vantagens

- Evita mínimos locais.
- Reduz problema de gradientes diluídos.
- Permite uso de dados não rotulados.

7 Autoencoder Esparso

- Impõe uma penalização $\Omega(h)$ para reduzir o número de ativações.
- Mesmo com camada latente maior que a entrada, força representação com poucos nodos ativos.
- Função de custo inclui termo de esparsidade.

8 Autoencoder Convolucional

- Compartilha pesos em regiões locais da entrada (ex.: imagens 32x32 com filtros 3x3).
- Reduz a quantidade de parâmetros.
- Explora propriedades espaciais dos dados.

9 Autoencoder Denoising

- Entrada é corrompida com ruído aleatório.
- Objetivo é reconstruir a entrada original a partir da versão ruidosa.
- Estimula a rede a aprender representações robustas.
- Pode ser empilhado como no *Stacked Denoising Autoencoder* (SDA).

10 Ferramentas

- **TensorFlow** (Google)
- **PyTorch** (Facebook)
- **Keras** (François Chollet)
- **MXNet, Caffe, Theano, Torch, Deeplearning4j, Apache SINGA**

11 Referências

- Bengio, Y. et al. (2007). Greedy layer-wise training of deep networks.
- Vincent, P. et al. (2010). Stacked denoising autoencoders.
- Schmidhuber, J. (2015). Deep learning in neural networks: An overview.
- Du, K.-L. & Swamy, M. N. S. (2019). Neural Networks and Statistical Learning.
- <https://arxiv.org/pdf/1812.05069.pdf>