

Resumo: Redes Neurais Convolucionais (CNNs)

joao.vmcardoso

1 Motivação

A busca por inteligência computacional requer que os computadores armazenem e processem informações do mundo real, tarefa realizada por algoritmos de aprendizado. O desafio permanece em criar sistemas capazes de entender e descrever cenas, interagir semanticamente com humanos, e representar imagens através de abstrações progressivas como bordas, formas e categorias.

1.1 Desafios das Redes Neurais Tradicionais

Redes neurais artificiais tradicionais (como o MLP) enfrentam a maldição da dimensionalidade, difusão de gradiente, dificuldade de generalização, mínimos locais e escassez de dados rotulados.

1.2 Surgimento da Aprendizagem Profunda

A aprendizagem profunda (deep learning) resolve parte dessas limitações ao aprender representações em múltiplos níveis de abstração. Técnicas como pré-treinamento não supervisionado camada por camada (Hinton, 2006) ajudaram a superar os problemas de mínimos locais.

2 Por que Aprendizagem Profunda?

- Possui plausibilidade biológica, inspirada no córtex visual.
- Pode representar funções complexas de forma mais eficiente com múltiplas camadas.

- Estudos mostram que redes mais profundas obtêm melhor desempenho mesmo com o mesmo número de parâmetros.
- Permite reutilização de características aprendidas para múltiplas tarefas.

3 Redes Neurais Convolucionais (CNNs)

3.1 Definição e Operações Básicas

CNNs são redes projetadas para processar dados com estrutura de grade, como imagens. Elas utilizam três operações principais:

- **Convolução:** operação linear sobre os dados.
- **Inserção de não-linearidade:** funções como ReLU e Leaky ReLU.
- **Subamostragem (pooling):** redução da resolução preservando informações relevantes.

3.2 Evidência Biológica e Histórica

- Inspiradas no trabalho de Hubel e Wiesel (1968) sobre células receptivas simples e complexas.
- Modelos como o Neo-Cognitron (Fukushima, 1980), MLP (Rumelhart, 1986) e CNNs de LeCun (1998) contribuíram para a evolução.

4 Arquitetura das CNNs

Uma CNN típica é composta por:

1. Camada de entrada (ex: 28x28 pixels).
2. Camadas convolucionais com filtros aprendidos (ex: 5x5).
3. Camadas de pooling (ex: 2x2).
4. Camadas totalmente conectadas (FC) para classificação.

4.1 Parâmetros de Configuração

- Margens (padding).
- Tamanho do kernel.
- Stride (passo).
- Quantidade e configuração dos filtros.

4.2 Conceitos Adicionais

- **Campos receptivos locais:** conectividade esparsa.
- **Compartilhamento de pesos:** reduz parâmetros livres.
- **Extração e mapeamento de características:** feito camada a camada.
- **Aprendizado supervisionado:** ajusta todos os pesos.

5 Treinamento de CNNs

O processo de treinamento envolve:

1. Inicialização aleatória dos pesos.
2. Propagação direta da entrada.
3. Cálculo do erro na saída.
4. Retropropagação do erro (backpropagation).
5. Atualização dos pesos com gradiente descendente.

O aprendizado estocástico (batch size 1) é comum. O uso de GPUs e técnicas como pré-treinamento não supervisionado aceleraram o sucesso de CNNs modernas.

6 Modelos de Sucesso

- LeNet (1998)
- AlexNet (2012)
- VGGNet (2014)
- ResNet (2015)

Esses modelos tiveram impacto direto nas competições de classificação de imagens como o ILSVRC (ImageNet Large Scale Visual Recognition Challenge).

7 Ferramentas Populares para Deep Learning

- **TensorFlow** – Google.
- **PyTorch** – Facebook.
- **Keras** – Interface de alto nível.
- **Theano**, **Caffe**, **MXNet**, **Deeplearning4j**, **Torch**, entre outros.

8 Referências

- Bengio et al., 2007.
- Schmidhuber, 2015.
- Vincent et al., 2010.
- <http://yann.lecun.com/exdb/publis/pdf/lecun-01a.pdf>
- <https://cs.nju.edu.cn/wujx/paper/CNN.pdf>
- <https://arxiv.org/pdf/1812.05069.pdf>