

Resumo sobre MLP-BP (Multilayer Perceptron com Backpropagation)

joao.vmcardoso

7 de junho de 2025

1 Introdução

O **Perceptron Multicamadas** (MLP - *Multilayer Perceptron*) com **retropropagação do erro** (BP - *Backpropagation*) é uma arquitetura de rede neural amplamente utilizada em tarefas de classificação, regressão e reconhecimento de padrões. Trata-se de uma rede neural feedforward composta por uma ou mais camadas ocultas entre a camada de entrada e a de saída.

2 Arquitetura do MLP

O MLP é formado por:

- Uma **camada de entrada**, responsável por receber os dados de entrada.
- Uma ou mais **camadas ocultas**, onde ocorre o processamento intermediário.
- Uma **camada de saída**, que fornece o resultado final do processamento.

Cada neurônio em uma camada é conectado a todos os neurônios da camada seguinte, formando uma rede totalmente conectada. Os neurônios aplicam uma função de ativação não linear, como a função sigmoide, tangente hiperbólica ou ReLU.

3 Algoritmo de Treinamento: Backpropagation

O algoritmo de **backpropagation** é usado para ajustar os pesos da rede durante o treinamento supervisionado. O processo consiste nas seguintes etapas:

1. **Propagação direta (feedforward)**: os dados de entrada percorrem a rede até a camada de saída, gerando uma predição.
2. **Cálculo do erro**: a diferença entre a saída obtida e a saída desejada (erro) é calculada usando uma função de custo, como o erro quadrático médio (MSE).
3. **Retropropagação do erro**: o erro é propagado para trás, da saída para a entrada, calculando os gradientes dos pesos.
4. **Atualização dos pesos**: os pesos são ajustados com base nos gradientes calculados, geralmente utilizando o algoritmo do gradiente descendente ou uma de suas variantes (como o gradiente descendente com momento ou o Adam).

4 Funções de Ativação

Algumas funções comuns usadas nos neurônios incluem:

- **Sigmoide:** $\sigma(x) = \frac{1}{1+e^{-x}}$
- **Tangente hiperbólica:** $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
- **ReLU (Rectified Linear Unit):** $f(x) = \max(0, x)$

5 Aplicações

MLP-BP é utilizado em diversas áreas, como:

- Reconhecimento de voz e imagem
- Diagnóstico médico
- Previsão de séries temporais
- Detecção de fraudes
- Sistemas de recomendação

6 Vantagens e Desvantagens

Vantagens

- Capacidade de aprender funções complexas não lineares
- Generalização a novos dados
- Flexibilidade com diferentes funções de ativação e arquiteturas

Desvantagens

- Necessidade de ajuste de muitos hiperparâmetros
- Alto custo computacional em redes profundas
- Suscetível ao overfitting se não regularizada adequadamente

7 Conclusão

O MLP com retropropagação é uma ferramenta poderosa em aprendizado de máquina, especialmente útil para problemas onde a relação entre entrada e saída não é linear. Apesar de seus desafios, sua eficácia em diversas aplicações o torna uma das arquiteturas mais estudadas e utilizadas.

8 Slides

8.1 Introdução

O documento aborda o Perceptron Multi-camadas (MLP - *Multilayer Perceptron*) treinado pelo algoritmo de retropropagação (BP - *Backpropagation*), uma rede neural supervisionada que utiliza métodos derivados do gradiente para ajuste de pesos. O MLP consiste em:

- Camada de entrada
- Uma ou mais camadas escondidas
- Camada de saída
- Unidade de *bias*

8.1.1 Características do MLP-BP

- Função de ativação sigmoideal (não-linear, suave e diferenciável)
- Alta conectividade entre neurônios
- Capacidade de aprender tarefas complexas através de camadas escondidas

8.2 Histórico

- Perceptron de Rosenblatt (1958): Limitado a problemas linearmente separáveis
- Algoritmo LMS (Widrow & Hoff, 1960)
- Desenvolvimento do MLP-BP:
 - Werbos (1974): Primeira descrição da retropropagação
 - Parker (1982,1985)
 - Rumelhart, Hinton e Williams (1986): Popularização do algoritmo

8.3 Algoritmo MLP-BP

8.4 Passos Básicos

1. Propagação direta (entrada $\rightarrow$ saída)
2. Cálculo do erro: $e_k(n) = t_k(n) - y_k(n)$
3. Retropropagação do erro (saída $\rightarrow$ entrada)
4. Atualização dos pesos: $\Delta w_{pq} = -\eta \frac{\partial E}{\partial w_{pq}}$

8.4.1 Funções de Ativação

- Sigmoide: $f(x) = \frac{1}{1+e^{-ax}}$
- Tangente hiperbólica: $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

8.5 Aproximação de Funções

- Teorema da Aproximação Universal: MLP com uma camada escondida pode aproximar qualquer função contínua
- Relação com séries de Fourier
- Trade-off entre número de neurônios escondidos e precisão da aproximação

8.6 Generalização

- Problema de sobre-ajuste (*overfitting*)
- Fatores que influenciam:
 - Tamanho e representatividade do conjunto de treinamento
 - Arquitetura da rede
 - Complexidade do problema
- Técnicas para melhorar generalização:
 - Validação cruzada
 - Regularização
 - Adição de ruído

8.7 Protocolos de Treinamento

- *Batch*: Atualização dos pesos após toda época
- *Online*: Atualização a cada padrão
- *Estocástico*: Seleção aleatória de padrões

8.8 Vantagens e Desvantagens

8.8.1 Vantagens

- Alto poder de representação (funções L2)
- Larga aplicabilidade
- Tolerância a dados ruidosos
- Facilidade de implementação

8.8.2 Desvantagens

- Convergência lenta para problemas complexos
- Modelo "caixa preta"
- Risco de mínimos locais
- Problemas de saturação (funções sigmóides)

8.9 Técnicas de Melhoria

- Termo de momento: $w(m+1) = w(m) + (1-\alpha)\Delta w_{bp}(m) + \alpha\Delta w(m-1)$
- Taxa de aprendizagem adaptativa
- Inicialização adequada de pesos
- Poda de rede
- Aprendizagem por pistas (*hints*)

8.10 Conclusão

O MLP-BP é uma arquitetura poderosa para aprendizado de máquina, capaz de aproximar funções complexas, mas que requer cuidados no treinamento e ajuste de parâmetros para obter bons resultados. O documento apresenta uma visão abrangente dos aspectos teóricos e práticos dessa rede neural.