

Comparação entre MLP-BP e RBF

joao.vmcardoso

1 Introdução

Este documento apresenta as principais diferenças entre os modelos MLP-BP (Multilayer Perceptron com Backpropagation) e RBF (Radial Basis Function).

2 Arquitetura e Camadas

2.1 MLP-BP

- Pode ter múltiplas camadas ocultas (geralmente uma ou mais)
- Camadas ocultas usam funções de ativação não lineares (como sigmoide ou ReLU)
- A saída pode ser linear ou não linear, dependendo da tarefa

2.2 RBF

- Possui apenas uma camada oculta não linear
- Neurônios ocultos usam funções de base radial (como Gaussianas)
- Camada de saída é sempre linear

3 Aprendizagem e Treinamento

3.1 MLP-BP

- Treinamento supervisionado via backpropagation

- Pode ser lento devido à necessidade de ajustar muitos pesos
- Sensível a inicialização dos pesos e pode cair em mínimos locais

3.2 RBF

- Combina aprendizagem não supervisionada e supervisionada
- Mais rápido que MLP-BP
- Menos propenso a mínimos locais

4 Aproximação de Funções

4.1 MLP-BP

- Realiza uma aproximação global dos dados
- Melhor para problemas com relações complexas e não lineares

4.2 RBF

- Faz uma aproximação local
- Mais eficaz para interpolação e problemas com padrões localizados

5 Desempenho e Aplicações

5.1 MLP-BP

- Mais flexível para tarefas complexas
- Pode exigir mais dados para treinamento

5.2 RBF

- Mais eficiente em problemas de classificação e regressão
- Menos eficaz em dados de alta dimensão

6 Interpretabilidade e Robustez

6.1 MLP-BP

- Funciona como uma "caixa preta"
- Pode ser mais robusto a ruídos

6.2 RBF

- Oferece maior transparência
- Sensível à escolha dos parâmetros

7 Resumo das Diferenças Principais

Tabela 1: Comparação entre MLP-BP e RBF

Característica	MLP-BP	RBF
Camadas Ocultas	Múltiplas	Única
Aprendizagem	Global (backpropagation)	Local (centros + ajuste linear)
Velocidade	Mais lento	Mais rápido
Aplicações Típicas	Problemas complexos (e.g., NLP)	Interpolação, classificação
Interpretabilidade	Baixa	Moderada

8 Conclusão

O MLP-BP é mais versátil para problemas complexos e de alta dimensão, enquanto o RBF é mais eficiente para tarefas com padrões locais e onde a interpretabilidade é importante. A escolha depende do problema específico e dos recursos computacionais disponíveis.