

Resumo: Redes de Função de Base Radial (RBF)

joao.vmcardoso

1 Introdução

As redes **RBF** (*Radial Basis Function*) são um tipo de rede neural artificial do tipo feedforward, amplamente utilizadas para tarefas de aproximação de funções, classificação e interpolação. Foram introduzidas como uma alternativa mais rápida e eficiente ao Perceptron Multicamadas (MLP), especialmente em contextos onde os dados apresentam comportamento localmente definido.

2 Arquitetura da RBF

Uma rede RBF é composta geralmente por três camadas:

- **Camada de entrada:** responsável por receber os dados de entrada.
- **Camada oculta:** utiliza funções de base radial como função de ativação. Cada neurônio responde fortemente apenas a uma região do espaço de entrada.
- **Camada de saída:** realiza uma combinação linear das saídas da camada oculta.

A principal característica das redes RBF está na camada oculta, onde são aplicadas funções de base radial, geralmente funções gaussianas.

3 Função de Base Radial

A função de ativação mais comum é a função gaussiana, definida como:

$$\phi(x) = \exp\left(-\frac{\|x - c\|^2}{2\sigma^2}\right)$$

onde:

- x é o vetor de entrada,
- c é o centro do neurônio,
- σ é o desvio padrão, que controla a largura da função radial.

4 Treinamento da Rede RBF

O treinamento das redes RBF geralmente ocorre em duas fases:

1. **Determinação dos centros e larguras (c e σ):** Pode ser realizada com técnicas como k-médias, clustering, ou métodos supervisionados.
2. **Ajuste dos pesos da camada de saída:** É realizado por métodos lineares, como a pseudo-inversa ou regressão linear.

5 Características e Aplicações

5.1 Vantagens

- Treinamento mais rápido em relação ao MLP
- Estrutura simples com interpretação local dos dados
- Boa capacidade de generalização com poucos neurônios

5.2 Desvantagens

- Sensível à escolha dos centros e larguras
- Pode exigir grande número de neurônios em problemas de alta dimensão
- Desempenho pode cair em dados ruidosos ou não-localmente separáveis

5.3 Aplicações

- Classificação de padrões
- Reconhecimento de escrita e voz
- Interpolação e aproximação de funções
- Controle e modelagem de sistemas dinâmicos

6 Conclusão

As redes RBF representam uma poderosa abordagem para modelagem de dados com características locais bem definidas. Sua estrutura simples e treinamento eficiente tornam-nas úteis em uma ampla gama de aplicações, desde tarefas de classificação até regressão e controle. No entanto, sua eficácia depende fortemente da escolha adequada dos centros e parâmetros da função radial.

7 Slides

7.1 Introdução

As Redes de Função de Base Radial (RBF) são redes neurais de múltiplas camadas que diferem das MLP-BP por:

- Utilizam unidades com campos receptivos locais
- Não empregam funções de ativação sigmoidais
- Combinam treinamento supervisionado e não-supervisionado
- São particularmente eficazes como interpoladores e aproximadores

7.1.1 Arquitetura Básica

- Camada de entrada: Propaga os estímulos
- Camada escondida: Transformação não-linear com campos receptivos locais
- Camada de saída: Combinação linear

7.2 Histórico

- Origem em técnicas de interpolação exata (Powell, 1987)
- Inspiração biológica em neurônios com resposta localmente sintonizada
- Desenvolvimentos importantes por:
 - Broomhead e Lowe (1988)
 - Moody e Darken (1989)
 - Poggio e Girosi (1990)

7.3 Teoria Fundamental

7.3.1 Teorema de Cover (1965)

- Problemas de classificação são mais prováveis de serem linearmente separáveis em espaços de alta dimensão
- Base matemática para a eficácia das RBFs

7.3.2 Teorema de Michelli (1986)

- Garante a não-singularidade da matriz de interpolação RBF
- Válido para qualquer número de pontos e tipos de funções de base radial

7.4 Funções de Base Radial

7.4.1 Principais Tipos

- Gaussiana: $\exp\left(-\frac{(x_p - \mu_j)^2}{2\sigma_j^2}\right)$
- *Thin-Plate Spline*: $r^2 \ln r$
- Multiquádrica: $\sqrt{r^2 + c^2}$
- Suportada compactamente: $(1 - \frac{r}{c})^4(4(\frac{r}{c}) + 1)$

7.5 Aprendizagem em Redes RBF

7.5.1 Abordagens

- Aprendizagem exata:
 - Número de nodos igual ao número de padrões ($H = N$)
 - Baixa capacidade de generalização
- Centros fixos escolhidos aleatoriamente:
 - $H < N$
 - Solução de equações lineares
- Aprendizagem não-supervisionada (*clustering*):
 - Algoritmos como K-means para determinar centros
 - LMS para ajuste de pesos
- Treinamento totalmente supervisionado

7.5.2 Determinação de Parâmetros

- Largura do campo receptivo (σ):
 - Distância euclidiana média entre centros
 - Variância dos grupos
- Algoritmo K-means para agrupamento:

$$\arg \min_S \sum_{i=1}^k \sum_{x \in S_i} \|x - \mu_i\|^2$$

7.6 Comparação entre RBF e MLP-BP

- **Velocidade:** RBF treina mais rápido
- **Generalização:** MLP-BP geralmente melhor
- **Sensibilidade:** RBF menos sensível a novos dados
- **Complexidade:** RBF pode requerer mais parâmetros
- **Geometria:** RBF usa hiperelipsoides, MLP-BP usa hiperplanos

7.7 Exemplo Prático

- Aproximação da função $y = \sin(x) - \sin(5x)$
- Efeito do tamanho do campo receptivo:
 - Campos pequenos: Sobreajuste
 - Campos grandes: Subajuste
- Demonstração da importância do ajuste adequado dos parâmetros

7.8 Conclusão

As redes RBF oferecem uma abordagem poderosa para problemas de aproximação e classificação, com vantagens específicas em cenários onde:

- Os dados são abundantes
- É necessário treinamento rápido
- A interpretação dos campos receptivos é importante

A escolha entre RBF e MLP-BP deve considerar as características específicas do problema e dos dados disponíveis.