

Resumo: Mapas Auto-Organizáveis (SOM) e Extensões

Baseado nos materiais de Aluizio Fausto Ribeiro Araújo

1 Introdução e Motivação

Mapas Auto-Organizáveis (Self-Organizing Maps, SOMs), propostos por Teuvo Kohonen em 1982, são um tipo de rede neural não-supervisionada que realiza mapeamento de dados de alta dimensão para um espaço de menor dimensão (geralmente 1D ou 2D), preservando relações topológicas entre amostras. São amplamente utilizados em clustering, visualização de dados e análise exploratória.

2 Fundamentos Biológicos e Computacionais

- Inspirados na organização topográfica do cérebro, como o mapa retinotópico.
- Um neurônio ativado excita vizinhos próximos e inibe regiões distantes (inibição lateral).
- Reproduz mecanismos de competição, cooperação e adaptação, análogos à neuroplasticidade.

3 Arquitetura e Funcionamento

3.1 Estrutura

- Camada de entrada: vetor de entrada $x \in \mathbb{R}^n$.
- Camada de saída: rede de unidades organizadas em grade (ex: 10x10).

- Cada unidade de saída tem um vetor de pesos $w_j \in \mathbb{R}^n$.

3.2 Processo de Treinamento

1. **Apresentação:** uma entrada x é fornecida.
2. **Competição:** identifica o Best Matching Unit (BMU) $v = \arg \min_j \|x - w_j\|$.
3. **Cooperação:** define a vizinhança topológica $h_{j,v}(n)$.
4. **Adaptação:** atualiza os pesos da BMU e seus vizinhos:

$$w_j(n+1) = w_j(n) + \eta(n)h_{j,v}(n)[x - w_j(n)]$$

3.3 Funções Temporais

- Taxa de aprendizagem decrescente: $\eta(n) = \eta_0 e^{-n/\tau_2}$.
- Raio da vizinhança decrescente: $\sigma(n) = \sigma_0 e^{-n/\tau_1}$.

4 Fases do Aprendizado

4.1 Ordenamento (Organização Grossa)

- Primeiras iterações com $\eta \in [0.1, 0.01]$.
- Visa capturar estrutura geral dos dados.

4.2 Convergência (Ajuste Fino)

- Diminuição da vizinhança.
- Refinamento local dos protótipos.

5 Propriedades dos SOMs

- Preservação topológica.
- Redução de dimensionalidade.
- Mapeamento contínuo e discreto.
- Adaptabilidade ao espaço de entrada.
- Capacidade de representar regiões densas com mais unidades.

6 Exemplos Clássicos

- Clustering de cores (valores RGB).
- WEBSOM: categorização semântica de documentos em larga escala.
- Análise de dados médicos, industriais e financeiros.

7 Vantagens dos SOMs

- Fácil visualização de agrupamentos complexos.
- Interpretação intuitiva dos mapas.
- Independente de suposições estatísticas rígidas.
- Simples implementação e robustez em aplicações reais.

8 Limitações Clássicas

- Tamanho e topologia fixos.
- Uso exclusivo da distância euclidiana.
- Sensível à inicialização.
- Baixa capacidade de detectar subgrupos muito sutis.

9 Extensões dos SOMs

9.1 HSOM – Hiperbólico

- Adota plano hiperbólico para melhor escalabilidade.
- Crescimento exponencial da vizinhança.
- Aplicações em categorização de textos.

9.2 PSOM – Parameterizado

- Usa pesos distintos para cada dimensão.
- Ideal para bases pequenas.
- Aplicado em controle de robôs.

9.3 BSOM – Bayesiano

- Usa probabilidade a posteriori para competição.
- Mistura de gaussianas para modelar distribuições complexas.

9.4 Kernel SOM

- Mapeia dados para espaço de alta dimensão via kernel $\kappa(x, y)$.
- Permite trabalhar com dados não linearmente separáveis.

9.5 GHSOM – Hierárquico

- Expande estrutura dinamicamente.
- Organização multi-nível para representar dados complexos.

9.6 GNG – Growing Neural Gas

- Grafo dinâmico que representa topologia do espaço.
- Insere e remove nós com base no erro acumulado.

10 Aplicações Práticas

- Visualização de grandes volumes de dados.
- Clustering e compressão de imagens.
- Bioinformática, finanças, robótica, monitoramento de redes.

11 Ferramentas e Pacotes

- **SOM PAK**: pacote original de Kohonen.
- **MiniSom (Python)**, **SOMToolbox (Matlab)**.
- Bibliotecas em C++, R, TensorFlow, PyTorch.

12 Referências Clássicas

- Kohonen, T. (1982, 2013, 2014).
- Fritzke, B. (1995). Growing Neural Gas.
- Dittenbach, M. et al. (2000). GHSOM.
- Ontrup & Ritter (2001). Hyperbolic SOM.
- Yin & Allinson (2001). Bayesian SOM.