

Resumo sobre Máquinas de Vetores de Suporte (SVM)

joao.vmcardoso

6 de junho de 2025

1 Introdução

As **Máquinas de Vetores de Suporte** (SVM - *Support Vector Machines*) são algoritmos de aprendizado supervisionado amplamente utilizados em tarefas de classificação e regressão. Desenvolvidas inicialmente por Vladimir Vapnik, as SVMs baseiam-se em conceitos da teoria de aprendizado estatístico e da otimização convexa.

O principal objetivo de uma SVM é encontrar um hiperplano ótimo que separe os dados em diferentes classes com a maior margem possível.

2 Conceitos Fundamentais

2.1 Separação Linear

Dado um conjunto de dados linearmente separáveis, a SVM busca um hiperplano que maximize a **margem**, ou seja, a distância entre o hiperplano e os pontos de dados mais próximos de cada classe (os *vetores de suporte*).

O hiperplano de separação pode ser representado por:

$$f(x) = w^T x + b = 0$$

onde:

- w é o vetor normal ao hiperplano;
- b é o viés (bias).

A margem é maximizada ao minimizar $\|w\|^2$ sob restrições que garantam a correta separação dos dados:

$$y_i(w^T x_i + b) \geq 1, \quad \forall i$$

2.2 Casos Não Linearmente Separáveis

Quando os dados não são linearmente separáveis, introduz-se um **termo de penalização** com variáveis de folga ξ_i , resultando no modelo **SVM suave** (*soft-margin*):

$$\min_{w,b,\xi} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

sujeito a:

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

O parâmetro C controla o balanço entre margem larga e penalização de erros de classificação.

2.3 Função Kernel

Para lidar com separações não lineares, as SVMs utilizam o **truque do kernel**, mapeando os dados para um espaço de maior dimensão onde é possível uma separação linear. A função kernel $K(x_i, x_j)$ define um produto interno no novo espaço, evitando o cálculo explícito do mapeamento.

Alguns kernels comuns:

- Linear: $K(x_i, x_j) = x_i^T x_j$
- Polinomial: $K(x_i, x_j) = (x_i^T x_j + r)^d$
- RBF (Gaussiano): $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- Sigmoidal: $K(x_i, x_j) = \tanh(\kappa x_i^T x_j + \theta)$

3 SVM para Regressão

A SVM pode ser adaptada para regressão, no modelo chamado **SVR (Support Vector Regression)**. O objetivo é encontrar uma função que desvie no máximo ϵ dos valores reais, penalizando os erros maiores que ϵ .

4 Vantagens e Desvantagens

4.1 Vantagens

- Alta eficácia em espaços de alta dimensão
- Flexibilidade através da escolha do kernel
- Robusta contra overfitting em muitos casos

4.2 Desvantagens

- Custo computacional elevado com grandes volumes de dados
- Requer escolha cuidadosa do kernel e parâmetros (C , γ , etc.)
- Dificuldade de interpretação do modelo em aplicações reais

5 Aplicações

As SVMs são aplicadas em diversas áreas:

- Reconhecimento de padrões (voz, imagem, escrita)
- Bioinformática (classificação de genes, proteínas)
- Detecção de fraudes
- Análise de sentimentos e mineração de texto

6 Conclusão

As Máquinas de Vetores de Suporte são modelos poderosos e versáteis no campo de aprendizado supervisionado, capazes de resolver problemas complexos de classificação e regressão. Através da maximização da margem e do uso de funções kernel, as SVMs oferecem alta capacidade de generalização. No entanto, seu uso eficaz exige atenção na escolha de parâmetros e kernel adequados para cada problema.

7 Slides

7.1 Introdução

As Máquinas de Vetores de Suporte (SVMs) são classificadores baseados na Teoria de Aprendizagem Estatística desenvolvida por Vapnik e Chernovenkis. Características principais:

- Baseiam-se na minimização do risco estrutural (compromisso entre erro de treinamento e capacidade de generalização)
- Buscam o hiperplano ótimo que maximiza a margem entre classes
- Podem lidar com problemas linearmente não-separáveis através de kernels
- Aplicações em classificação, regressão e reconhecimento de padrões

7.2 Teoria Fundamental

7.2.1 Minimização do Risco Estrutural

- Risco esperado $\leq$ risco empírico + termo de complexidade
- Equação com dimensão VC (h):

$$R[f] \leq R_{emp}[f] + \sqrt{\frac{h(\ln \frac{2n}{h} + 1) - \ln \frac{\delta}{4}}{n}}$$

7.2.2 Dimensão VC

- Medida da capacidade de um classificador
- Cardinalidade do maior conjunto de pontos que pode ser separado em todas as 2^n configurações possíveis
- Para classificadores lineares em $\mathbb{R}^2$, $h = 3$

7.3 SVM para Dados Linearmente Separáveis

7.3.1 Hiperplano Ótimo

- Equação do hiperplano: $\mathbf{w}^T \mathbf{x} + b = 0$
- Maximização da margem $\rho_0 = \frac{2}{\|\mathbf{w}\|}$
- Vetores de suporte satisfazem $|\mathbf{w}^T \mathbf{x} + b| = 1$

7.3.2 Formulação Matemática

Problema de otimização:

$$\text{Minimizar } \Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

Sujeito a:

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, N$$

Solução via multiplicadores de Lagrange:

$$\mathbf{w} = \sum_{i=1}^N \alpha_i d_i \mathbf{x}_i$$

$$\sum_{i=1}^N \alpha_i d_i = 0$$

7.4 SVM para Dados Não-Linearmente Separáveis

7.4.1 Margens Flexíveis

- Introdução de variáveis de folga (ξ_i)
- Nova função objetivo:

$$\Phi(\mathbf{w}, \xi) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i$$

7.4.2 Kernel Trick

- Mapeamento para espaços de maior dimensão via $\Phi(\mathbf{x})$
- Funções kernel calculam produtos internos implicitamente:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_j)$$

- Exemplos de kernels:
 - Gaussiano: $e^{-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2}$
 - Polinomial: $(\mathbf{x}_i^T \mathbf{x}_j + c)^d$
 - Sigmoidal: $\tanh(\kappa \mathbf{x}_i^T \mathbf{x}_j + \theta)$

7.5 Extensões de SVM

7.5.1 SVM para Múltiplas Classes

- Abordagem "um contra todos":
 - k classificadores binários
 - Cada um separa uma classe das demais
- Abordagem "um contra um":
 - $k(k-1)/2$ classificadores binários
 - Cada um separa um par de classes

7.5.2 Métodos de Treinamento

- Matriz de Kernel reduzida
- ν -SVM
- Técnica de Planos de Corte
- Baseado no Gradiente

7.6 Aplicações

- Reconhecimento de caracteres manuscritos (USPS dataset)
- Detecção de faces em imagens
- Classificação de textos
- Bioinformática

7.7 Discussão

- Vantagens:
 - Base teórica sólida
 - Boa generalização
 - Eficiência computacional
- Limitações:
 - Sensibilidade a parâmetros
 - Dificuldade com dados ruidosos
 - Escalabilidade para grandes conjuntos de dados